



**INGENIERÍA
INDUSTRIAL**

UNIVERSIDAD DE SANTIAGO DE CHILE

Estadística y Probabilidades

Luis Rojo-González, Ph.D.




Mapa del curso



INGENIERÍA
INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso
2. Conceptos básicos de probabilidad
3. Bayes, variables aleatorias y distribuciones
4. Esperanza, varianza y desviación estándar
5. Modelos probabilísticos discretos
6. Modelos probabilísticos continuos
7. Conceptos básicos de estadística
8. Propiedades de estimadores y Teorema Central del Límite
9. Intervalos de confianza e introducción a hipótesis
10. Pruebas de hipótesis paramétricas
11. Pruebas para muestras pareadas



Propósito del curso



Objetivo general

Desarrollar herramientas fundamentales de probabilidad y estadística para modelar incertidumbre, analizar variabilidad y apoyar decisiones cuantitativas en contextos de Ingeniería Industrial.

¿Qué busca desarrollar el curso?


- Comprensión de fenómenos aleatorios e incertidumbre.
- Interpretación probabilística de eventos y riesgos.
- Modelamiento de procesos discretos y continuos.
- Análisis estadístico de datos industriales.
- Inferencia y toma de decisiones basadas en muestras.
- Uso introductorio de simulación y análisis en R.

Ingeniería Industrial

- Control de calidad.
- Gestión de inventarios.
- Pronóstico y demanda.
- Riesgo operacional.
- Evaluación y mejora de procesos.



1. Bienvenida al curso
2. Conceptos básicos de probabilidad
3. Bayes, variables aleatorias y distribuciones
4. Esperanza, varianza y desviación estándar
5. Modelos probabilísticos discretos
6. Modelos probabilísticos continuos
7. Conceptos básicos de estadística
8. Propiedades de estimadores y Teorema Central del Límite
9. Intervalos de confianza e introducción a hipótesis
10. Pruebas de hipótesis paramétricas
11. Pruebas para muestras pareadas



Planificación



Semana	Unidad	Evaluación	Fecha
1 (02/09/2026)	Conceptos básicos de probabilidad		
2 (09/09/2026)	Bayes, variable aleatoria y distribuciones		
3 (23/09/2026)	Esperanza, varianza y desviación estándar		
4 (30/09/2026)	Modelos probabilísticos discretos		
5 (07/10/2026)	Modelos probabilísticos continuos		
6 (14/10/2026)	Conceptos básicos de estadística		
		Control 1	21/10/2026
		PEP 1	28/10/2026
9 (04/11/2026)	Propiedades de estimadores		
10 (11/11/2026)	Teorema Central del límite		
11 (18/11/2026)	Intervalos de confianza, introducción a hipótesis y Pruebas de hipótesis paramétricas		
		Control 2	25/11/2026
13 (02/12/2026)	Pruebas para muestras pareadas, Bondad de ajuste, independencia y homogeneidad		
		PEP 2	09/12/2026
15 (16/12/2026)	Consultas POR		
		POR	23/12/2026

¿Cómo se aprueba el curso?



Evaluaciones regulares

Evaluación	Ponderación
Control 1	15 %
PEP 1	35 %
Control 2	15 %
PEP 2	35 %

$$NF = 0.15 C_1 + 0.35 P_1 + 0.15 C_2 + 0.35 P_2$$

Prueba recuperativa: POR

La **POR** permite recuperar una de las dos PEP.

PEP → POR

La POR reemplaza su nota

Por lo tanto, **no corresponde a una evaluación adicional** ni modifica las ponderaciones del curso.

Nivel de exigencia

En todas las evaluaciones se utiliza un nivel de exigencia de **60 %**.

Estructura pedagógica de cada unidad



Secuencia de aprendizaje

1. Problema industrial y motivación operacional.
2. Interpretación intuitiva de la incertidumbre.
3. Desarrollo conceptual y formulación matemática.
4. Visualización mediante gráficos y simulación.
5. Implementación y análisis en R.
6. Interpretación estadística y toma de decisiones.
7. Discusión crítica, supuestos y errores frecuentes.

Idea clave

El curso busca desarrollar pensamiento probabilístico y criterio estadístico para modelar variabilidad, interpretar datos y apoyar decisiones cuantitativas en Ingeniería Industrial.

Actividad: Dinámica recurrente

En cada clase se trabajará con: interpretación de fenómenos aleatorios, análisis de gráficos y distribuciones, simulaciones y visualizaciones en R, discusión de decisiones industriales bajo incertidumbre.


Mapa del curso



INGENIERÍA
INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso
2. Conceptos básicos de probabilidad
 - 2.1 Motivación y lenguaje
 - 2.2 Reglas básicas
 - 2.3 Ejercicios y cierre
3. Bayes, variables aleatorias y distribuciones
4. Esperanza, varianza y desviación estándar
5. Modelos probabilísticos discretos
6. Modelos probabilísticos continuos
7. Conceptos básicos de estadística
8. Propiedades de estimadores y Teorema Central del Límite
9. Intervalos de confianza e introducción a hipótesis
10. Pruebas de hipótesis paramétricas
11. Pruebas para muestras pareadas






Pregunta típica

Una empresa promete entregar pedidos en menos de 24 horas. Históricamente, el 8 % llega atrasado. ¿Cómo cuantificar ese riesgo y planificar capacidad?

- La operación real contiene variabilidad: demanda, tiempos de proceso, disponibilidad de equipos, congestión y errores.
- La probabilidad permite asignar números a esa incertidumbre.
- El objetivo no es eliminar toda incertidumbre, sino decidir mejor bajo ella.




Objetivos de aprendizaje



Al finalizar esta clase, el estudiante debería poder:

1. Definir experimento aleatorio, espacio muestral y evento.
2. Interpretar probabilidades como medidas de incertidumbre.
3. Usar complemento, unión, intersección y probabilidad condicional.
4. Distinguir independencia de exclusión mutua.
5. Resolver problemas aplicados a manufactura, calidad y logística.




Incertidumbre en sistemas industriales



- ¿Cuántos clientes llegarán mañana?
- ¿Cuánto tardará una reparación?
- ¿Qué fracción de piezas será defectuosa?
- ¿Llegará a tiempo el proveedor?
- ¿Habrá quiebre de stock?

Idea

Una decisión industrial rara vez se toma con certeza absoluta. La probabilidad ayuda a expresar el riesgo de cada escenario.






Definición

Un **experimento aleatorio** es un proceso cuyo resultado no puede conocerse con certeza antes de observarlo, aunque sí conocemos los resultados posibles.

Examples

- Inspeccionar una pieza: buena o defectuosa.
- Registrar si un pedido llega a tiempo o atrasado.
- Contar llamadas recibidas en una hora.
- Medir el tiempo de atención de un cliente.





Espacio muestral


El espacio muestral S contiene todos los resultados posibles del experimento.

Evento

Un evento A es un subconjunto de S . Ocurre si el resultado observado pertenece a A .

Ejemplo

Lanzar un dado: $S = \{1, 2, 3, 4, 5, 6\}$. Evento “número par”: $A = \{2, 4, 6\}$.






Una línea produce artículos que se clasifican como conformes o no conformes.

$$S = \{C, NC\}$$

- C : pieza conforme.
- NC : pieza no conforme.

Interpretación

El evento NC es operacionalmente importante porque puede activar inspección adicional, reproceso, costos de garantía o rechazo del lote.






Cuando todos los resultados elementales son igualmente probables:

$$\mathbb{P}(A) = \frac{\text{casos favorables a } A}{\text{casos posibles}}.$$

Ejemplo

Si se elige aleatoriamente una de 6 máquinas y 2 están en mantenimiento:

$$\mathbb{P}(\text{elegir máquina en mantenimiento}) = \frac{2}{6} = 0.333.$$



Axiomas operacionales de probabilidad




Toda probabilidad debe cumplir:

1. $0 \leq \mathbb{P}(A) \leq 1$.
2. $\mathbb{P}(S) = 1$.
3. Si A y B no pueden ocurrir simultáneamente, entonces

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B).$$

Lectura práctica

Una probabilidad cercana a 1 indica un evento muy probable; una cercana a 0 indica un evento raro, pero no imposible.





Definición


El complemento A^c representa que el evento A no ocurre.

$$\mathbb{P}(A^c) = 1 - \mathbb{P}(A).$$

Ejemplo

Si la probabilidad de atraso de un camión es 0.08, entonces la probabilidad de que llegue a tiempo es:

$$1 - 0.08 = 0.92.$$





Unión e intersección



- $A \cup B$: ocurre A , ocurre B o ambos.
- $A \cap B$: ocurren A y B simultáneamente.

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$



Ejemplo resuelto: pedidos tardíos o dañados




En una empresa logística:

- $\mathbb{P}(T) = 0.40$: pedido tardío.
- $\mathbb{P}(D) = 0.15$: pedido dañado.
- $\mathbb{P}(T \cap D) = 0.05$: tardío y dañado.

$$\mathbb{P}(T \cup D) = 0.40 + 0.15 - 0.05 = 0.50.$$

Interpretación

La mitad de los pedidos presenta al menos uno de los dos problemas. La intersección se resta porque esos pedidos fueron contados dos veces.






Definición

La probabilidad de A dado que ocurrió B es

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}, \quad \mathbb{P}(B) > 0.$$

- B redefine el universo de análisis.
- Preguntamos qué proporción de los casos en B también pertenece a A .



Ejemplo resuelto: falla eléctrica dado daño mecánico



Una planta reporta:


- $\mathbb{P}(E \cap M) = 0.04$: falla eléctrica y daño mecánico.
- $\mathbb{P}(M) = 0.20$: daño mecánico.

Entonces:

$$\mathbb{P}(E \mid M) = \frac{0.04}{0.20} = 0.20.$$

Interpretación

Entre los productos con daño mecánico, el 20 % también presenta falla eléctrica.





Definición operacional


Dos eventos son independientes si saber que ocurrió uno no cambia la probabilidad del otro.

Equivalencias útiles:

$$\mathbb{P}(A \mid B) = \mathbb{P}(A), \quad \mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

Cuidado

Independencia no significa que los eventos no puedan ocurrir juntos. Eso corresponde a eventos mutuamente excluyentes.



Ejemplo: independencia en dos estaciones




Dos estaciones de trabajo fallan de forma independiente durante un turno.

- $\mathbb{P}(F_1) = 0.04$.
- $\mathbb{P}(F_2) = 0.03$.

$$\mathbb{P}(F_1 \cap F_2) = 0.04 \times 0.03 = 0.0012.$$

Lectura

La probabilidad de que ambas fallen en el mismo turno es 0.12 %, siempre que la hipótesis de independencia sea razonable.






Ejercicio 1.

Una fábrica registra que:

- 70 % de las piezas cumplen norma dimensional.
- 15 % tienen defecto superficial.
- 10 % cumplen norma dimensional y tienen defecto superficial.

Calcule:

1. Probabilidad de cumplir norma o tener defecto superficial.
2. Probabilidad de no tener defecto superficial.






Ejercicio 2.

En una empresa:

- 25 % de los pedidos son urgentes.
- 20 % de los pedidos se atrasan.
- 12 % son urgentes y atrasados.

Calcule la probabilidad de que un pedido sea urgente dado que está atrasado.






- Olvidar restar $\mathbb{P}(A \cap B)$ al calcular una unión.
- Confundir $\mathbb{P}(A | B)$ con $\mathbb{P}(B | A)$.
- Asumir independencia sin justificación operacional.
- Interpretar probabilidades como certezas.

Regla práctica

Antes de aplicar fórmulas, defina claramente los eventos y escriba qué se desea calcular.






- Los eventos representan resultados de interés dentro de un espacio muestral.
- La probabilidad cuantifica incertidumbre en una escala de 0 a 1.
- Complemento, unión, intersección y condicional son operaciones básicas.
- La independencia debe interpretarse y justificarse desde el proceso real.

Conexión

La próxima clase usa estas reglas para estudiar Bayes y variables aleatorias.



Mapa del curso



INGENIERÍA
INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso
2. Conceptos básicos de probabilidad
3. Bayes, variables aleatorias y distribuciones
 - 3.1 Bayes
 - 3.2 Variables aleatorias
 - 3.3 Ejercicios y cierre
4. Esperanza, varianza y desviación estándar
5. Modelos probabilísticos discretos
6. Modelos probabilísticos continuos
7. Conceptos básicos de estadística
8. Propiedades de estimadores y Teorema Central del Límite
9. Intervalos de confianza e introducción a hipótesis
10. Pruebas de hipótesis paramétricas
11. Pruebas para muestras pareadas






En ingeniería frecuentemente se observa una señal indirecta:

- Una alarma de calidad se activa.
- Un sensor detecta vibración alta.
- Un test clasifica un producto como defectuoso.

Pregunta central


Dada la señal observada, ¿cuál es la probabilidad de que realmente exista el problema?



Objetivos



1. Interpretar el Teorema de Bayes sin demostración formal.
2. Usar tablas y árboles para actualizar probabilidades.
3. Definir variables aleatorias discretas y continuas.
4. Diferenciar función de probabilidad, densidad y distribución acumulada.






Actualización de creencias



Bayes permite actualizar una probabilidad inicial usando nueva evidencia.

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(B \mid A)\mathbb{P}(A)}{\mathbb{P}(B)}.$$

- $\mathbb{P}(A)$: probabilidad previa.
- $\mathbb{P}(B \mid A)$: probabilidad de observar la evidencia si A ocurre.
- $\mathbb{P}(A \mid B)$: probabilidad posterior.



Árbol de probabilidad




Ejemplo resuelto: alarma de calidad



Un sistema detecta defectos:

- $\mathbb{P}(D) = 0.03$: producto realmente defectuoso.
- $\mathbb{P}(A | D) = 0.95$: alarma si es defectuoso.
- $\mathbb{P}(A | D^c) = 0.04$: falsa alarma si no es defectuoso.

Queremos $\mathbb{P}(D | A)$.



Solución: alarma de calidad



Primero calculamos la probabilidad total de alarma:

$$\mathbb{P}(A) = \mathbb{P}(A \mid D)\mathbb{P}(D) + \mathbb{P}(A \mid D^c)\mathbb{P}(D^c).$$

$$\mathbb{P}(A) = 0.95(0.03) + 0.04(0.97) = 0.0285 + 0.0388 = 0.0673.$$

Luego:

$$\mathbb{P}(D \mid A) = \frac{0.95(0.03)}{0.0673} = 0.4235.$$

Interpretación

Aunque la alarma es sensible, solo cerca del 42 % de las alarmas corresponde a defectos reales, porque los defectos son poco frecuentes.






Definición

Una variable aleatoria asigna un número a cada resultado de un experimento aleatorio.

Ejemplos

- X : número de piezas defectuosas en una muestra.
- T : tiempo de espera de un cliente.
- D : demanda diaria de un producto.
- Y : costo total de fallas en un turno.



Variables discretas y continuas



Discreta


Toma valores contables.

- número de defectos
- número de llamadas
- cantidad de órdenes

Continua

Toma valores en intervalos.

- tiempo de servicio
- peso de un producto
- temperatura de proceso



Función de probabilidad: caso discreto



Para una variable discreta X , la función de probabilidad es:


$$p(x) = \mathbb{P}(X = x).$$

Debe cumplir:

$$p(x) \geq 0, \quad \sum_x p(x) = 1.$$

Ejemplo

Si X es el número de defectos en una pieza: $X \in \{0, 1\}$.






Para una variable continua X , no se asigna probabilidad a un punto exacto, sino a intervalos.

$$\mathbb{P}(a \leq X \leq b) = \int_a^b f(x) dx.$$

Interpretación

$f(x)$ no es una probabilidad; es una densidad. El área bajo la curva representa probabilidad.



Función de distribución acumulada




La función de distribución acumulada se define como:

$$F(x) = \mathbb{P}(X \leq x).$$

- Funciona para variables discretas y continuas.
- Es creciente.
- Toma valores entre 0 y 1.

Interpretación industrial

Si X es tiempo de entrega, $F(24)$ es la probabilidad de entregar antes de 24 horas.






Idea

La distribución describe cómo se reparte la probabilidad entre los valores posibles de una variable aleatoria.

- En variables discretas: tabla de probabilidades.
- En variables continuas: curva de densidad.
- En ambos casos: la distribución permite calcular riesgos, percentiles y escenarios.




Ejemplo discreto: demanda diaria



La demanda diaria de un repuesto puede ser:

x	0	1	2	3
$\mathbb{P}(X = x)$	0.10	0.35	0.40	0.15

- $\mathbb{P}(X \leq 1) = 0.10 + 0.35 = 0.45$.
- $\mathbb{P}(X \geq 2) = 0.40 + 0.15 = 0.55$.



Ejemplo continuo: tiempo de atención




Sea T el tiempo de atención de un cliente.

- T puede tomar valores como 3.1, 3.15 o 3.157 minutos.
- Por ello se modela como continua.

Pregunta típica

¿Qué probabilidad hay de que la atención tarde menos de 5 minutos?

$$\mathbb{P}(T \leq 5) = F(5).$$




Ejercicio propuesto



Una prueba de diagnóstico para una máquina tiene:

- $\mathbb{P}(F) = 0.10$: la máquina está en condición de falla.
- $\mathbb{P}(S | F) = 0.90$: el sensor alerta si hay falla.
- $\mathbb{P}(S | F^c) = 0.08$: el sensor alerta sin falla real.

Calcule $\mathbb{P}(F | S)$.





Calculamos primero:

$$\mathbb{P}(S) = 0.90(0.10) + 0.08(0.90) = 0.09 + 0.072 = 0.162.$$

Luego:

$$\mathbb{P}(F | S) = \frac{0.90(0.10)}{0.162} = 0.5556.$$

Interpretación


Si el sensor alerta, la probabilidad de falla real es aproximadamente 55.6 %.



- Bayes actualiza probabilidades con evidencia.
- Una variable aleatoria convierte resultados en números analizables.
- Variables discretas usan funciones de probabilidad.
- Variables continuas usan densidades e integrales.
- La distribución acumulada resume probabilidades del tipo $\mathbb{P}(X \leq x)$.

Conexión

La siguiente clase estudia cómo resumir una distribución mediante esperanza, varianza y desviación estándar.




Mapa del curso



INGENIERÍA
INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso
2. Conceptos básicos de probabilidad
3. Bayes, variables aleatorias y distribuciones
4. **Esperanza, varianza y desviación estándar**
 - 4.1 Medidas de una distribución
 - 4.2 Dispersión
 - 4.3 Ejercicios y cierre
5. Modelos probabilísticos discretos
6. Modelos probabilísticos continuos
7. Conceptos básicos de estadística
8. Propiedades de estimadores y Teorema Central del Límite
9. Intervalos de confianza e introducción a hipótesis
10. Pruebas de hipótesis paramétricas
11. Pruebas para muestras pareadas






Una distribución completa puede contener mucha información. En ingeniería necesitamos resúmenes útiles:

- ¿Cuál es la demanda promedio esperada?
- ¿Qué tan variable es el tiempo de producción?
- ¿Cuál alternativa tiene mayor riesgo?


Idea

La esperanza resume el centro; la varianza y desviación estándar resumen la dispersión.



Objetivos

1. Definir esperanza para variables discretas y continuas.
2. Interpretar esperanza como promedio de largo plazo.
3. Calcular varianza y desviación estándar.
4. Comparar alternativas usando media y variabilidad.
5. Resolver ejemplos aplicados a costos, demanda y tiempos.



Esperanza: idea intuitiva




La esperanza de una variable aleatoria es su valor promedio en el largo plazo.

Interpretación

Si repetimos el proceso muchas veces, el promedio observado tenderá a estar cerca de $\mathbb{E}[X]$.

Ejemplo

Si X es demanda diaria, $\mathbb{E}[X]$ representa la demanda promedio esperada por día.




Esperanza discreta



Si X es discreta:

$$\mathbb{E}[X] = \sum_x x\mathbb{P}(X = x).$$

- Cada valor se pondera por su probabilidad.
- Valores más probables influyen más en el promedio esperado.



Ejemplo: demanda de repuestos




x	0	1	2	3
$\mathbb{P}(X = x)$	0.10	0.35	0.40	0.15

$$\mathbb{E}[X] = 0(0.10) + 1(0.35) + 2(0.40) + 3(0.15) = 1.60.$$

Interpretación

En promedio se demandan 1.6 repuestos por día. No significa que un día específico se vendan 1.6 unidades.






Si X es continua con densidad $f(x)$:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} xf(x) dx.$$

Lectura práctica

Es el centro de masa de la distribución. Para tiempos o pesos, representa el valor promedio esperado en muchas observaciones.



Linealidad de la esperanza



Para constantes a y b :

$$\mathbb{E}[aX + b] = a\mathbb{E}[X] + b.$$


Ejemplo

Si el costo total es $C = 500 + 20X$, donde X es número de defectos:

$$\mathbb{E}[C] = 500 + 20\mathbb{E}[X].$$

Importante

Esta propiedad no requiere independencia.





La varianza mide cuánto se aleja X de su media.


$$\text{Var}(X) = \mathbb{E}[(X - \mu)^2], \quad \mu = \mathbb{E}[X].$$

Forma computacional útil:

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2.$$

Interpretación

Mayor varianza implica mayor incertidumbre alrededor del promedio.



Desviación estándar




La desviación estándar es:

$$\sigma = \sqrt{\text{Var}(X)}.$$

- Se expresa en las mismas unidades de X .
- Facilita comparar variabilidad con la media.

Ejemplo

Si X mide minutos, σ también mide minutos.



Ejemplo: cálculo de varianza




Para la demanda anterior:

x	0	1	2	3
$\mathbb{P}(X = x)$	0.10	0.35	0.40	0.15

Ya obtuvimos $\mathbb{E}[X] = 1.60$.

$$\mathbb{E}[X^2] = 0^2(0.10) + 1^2(0.35) + 2^2(0.40) + 3^2(0.15) = 3.30.$$

$$\text{Var}(X) = 3.30 - 1.60^2 = 0.74, \quad \sigma = \sqrt{0.74} = 0.86.$$



Comparación de alternativas




Dos proveedores tienen el mismo tiempo promedio de entrega:

Proveedor	Media	Desv. estándar
A	5 días	1 día
B	5 días	3 días

Interpretación

Aunque ambos tienen el mismo promedio, el proveedor B es más riesgoso porque presenta mayor variabilidad.






Cuando las unidades o escalas son distintas, puede usarse:

$$CV = \frac{\sigma}{\mu}.$$

- Resume variabilidad relativa.
- Es útil para comparar productos con demandas promedio diferentes.

Cuidado

No es adecuado si la media está cerca de cero.



Esperanza de una función




Si el costo depende de X , no siempre basta con reemplazar X por $\mathbb{E}[X]$.

$$\mathbb{E}[g(X)] = \sum_x g(x) \mathbb{P}(X = x)$$

para variables discretas.

Ejemplo

Si hay penalización cuadrática por atraso, $g(X) = X^2$, entonces importa mucho la variabilidad.



Ejercicio propuesto




El número de fallas menores en un turno tiene distribución:

x	0	1	2
$\mathbb{P}(X = x)$	0.50	0.35	0.15

Calcule:

1. $\mathbb{E}[X]$.
2. $\text{Var}(X)$.
3. σ .



Solución del ejercicio



$$\mathbb{E}[X] = 0(0.50) + 1(0.35) + 2(0.15) = 0.65.$$


$$\mathbb{E}[X^2] = 0^2(0.50) + 1^2(0.35) + 2^2(0.15) = 0.95.$$

$$\text{Var}(X) = 0.95 - 0.65^2 = 0.5275.$$

$$\sigma = \sqrt{0.5275} = 0.726.$$

Interpretación

Se espera menos de una falla menor por turno, pero existe variabilidad relevante alrededor de ese valor.






- La esperanza es un promedio de largo plazo.
- La varianza mide dispersión cuadrática alrededor de la media.
- La desviación estándar vuelve la dispersión a las unidades originales.
- En decisiones industriales, no basta comparar promedios; también se debe comparar riesgo.

Conexión

Ahora estudiaremos modelos discretos específicos que permiten calcular probabilidades en problemas frecuentes.



Mapa del curso




INGENIERÍA
INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso
2. Conceptos básicos de probabilidad
3. Bayes, variables aleatorias y distribuciones
4. Esperanza, varianza y desviación estándar
- 5. Modelos probabilísticos discretos**
 - 5.1 Bernoulli y Binomial
 - 5.2 Geométrica y Pascal
 - 5.3 Hipergeométrica y Poisson
 - 5.4 Ejercicios y cierre
6. Modelos probabilísticos continuos
7. Conceptos básicos de estadística
8. Propiedades de estimadores y Teorema Central del Límite
9. Intervalos de confianza e introducción a hipótesis
10. Pruebas de hipótesis paramétricas
11. Pruebas para muestras pareadas

#SOMOSUSACH






Muchos procesos industriales se expresan mediante conteos:

- número de piezas defectuosas
- número de clientes que compran
- número de fallas en un lote
- número de llamadas recibidas

Idea


Los modelos discretos permiten representar conteos y decisiones sí/no.



Objetivos



1. Reconocer situaciones Bernoulli, Binomial, Geométrica, Pascal, Hipergeométrica y Poisson.
2. Calcular probabilidades usando cada modelo.
3. Interpretar parámetros y supuestos.
4. Elegir un modelo adecuado según el contexto industrial.






Una variable Bernoulli representa un experimento con dos resultados:

$$X = \begin{cases} 1, & \text{éxito,} \\ 0, & \text{fracaso.} \end{cases}$$

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p.$$

Ejemplo

Una pieza es defectuosa ($X = 1$) o no defectuosa ($X = 0$).



Media y varianza Bernoulli




Si $X \sim \text{Bernoulli}(p)$:

$$\mathbb{E}[X] = p, \quad \text{Var}(X) = p(1 - p).$$

Interpretación

La media es la proporción esperada de éxitos. La varianza es máxima cuando $p = 0.5$ y menor cuando el resultado es casi seguro.






Si repetimos n ensayos Bernoulli independientes, con la misma probabilidad de éxito p , y contamos éxitos:

$$X \sim \text{Bin}(n, p).$$

$$\mathbb{P}(X = x) = \binom{n}{x} p^x (1 - p)^{n-x}, \quad x = 0, 1, \dots, n.$$

Supuestos

Número fijo de ensayos, independencia, dos resultados y probabilidad constante.



Ejemplo Binomial: defectos en muestra




Una línea produce defectos con probabilidad $p = 0.04$. Se inspeccionan $n = 10$ piezas. Sea X el número de defectuosas.

$$X \sim \text{Bin}(10, 0.04).$$

Probabilidad de exactamente una defectuosa:

$$\mathbb{P}(X = 1) = \binom{10}{1} (0.04)^1 (0.96)^9 = 0.276.$$



Ejemplo Binomial: al menos una defectuosa




Usamos complemento:

$$\mathbb{P}(X \geq 1) = 1 - \mathbb{P}(X = 0).$$

$$\mathbb{P}(X \geq 1) = 1 - \binom{10}{0} (0.04)^0 (0.96)^{10} = 1 - 0.665 = 0.335.$$

Interpretación

Aunque la tasa individual sea 4 %, al revisar 10 piezas la probabilidad de encontrar al menos una defectuosa sube a 33.5 %.






La variable geométrica cuenta el número de ensayos hasta obtener el primer éxito.

$$X \sim \text{Geom}(p), \quad \mathbb{P}(X = x) = (1 - p)^{x-1}p,$$

para $x = 1, 2, \dots$

Ejemplo

Número de llamadas necesarias hasta conseguir la primera venta.



Ejemplo Geométrico




Un vendedor logra concretar una venta con probabilidad $p = 0.20$ en cada llamada.
¿Probabilidad de concretar la primera venta en la tercera llamada?

$$\mathbb{P}(X = 3) = (0.80)^2(0.20) = 0.128.$$

Interpretación

Debe fallar en las dos primeras llamadas y tener éxito en la tercera.



Modelo Pascal o Binomial negativa




Cuenta el número de ensayos necesarios para obtener r éxitos.

$$\mathbb{P}(X = x) = \binom{x-1}{r-1} p^r (1-p)^{x-r}, \quad x = r, r+1, \dots$$

Ejemplo

Número de inspecciones necesarias hasta encontrar 3 piezas defectuosas para análisis de causa raíz.





La probabilidad de que una pieza tenga cierto defecto es $p = 0.05$. ¿Probabilidad de encontrar el segundo defecto justo en la décima pieza inspeccionada?

$$\mathbb{P}(X = 10) = \binom{9}{1} (0.05)^2 (0.95)^8 = 0.149.$$

Lectura

En las primeras 9 piezas debe haber exactamente 1 defecto, y la pieza 10 debe ser defectuosa.






Se usa cuando se extrae una muestra sin reemplazo desde una población finita.

$$X \sim \text{Hipergeom}(N, K, n).$$

- N : tamaño de la población.
- K : número de elementos con la característica.
- n : tamaño de la muestra.

$$\mathbb{P}(X = x) = \frac{\binom{K}{x} \binom{N-K}{n-x}}{\binom{N}{n}}.$$



Ejemplo Hipergeométrico




Un lote tiene $N = 50$ piezas, de las cuales $K = 6$ son defectuosas. Se inspeccionan $n = 5$ sin reemplazo. Probabilidad de encontrar exactamente 1 defectuosa:

$$\mathbb{P}(X = 1) = \frac{\binom{6}{1} \binom{44}{4}}{\binom{50}{5}} = 0.384.$$

Interpretación

El muestreo sin reemplazo hace que la probabilidad cambie después de cada extracción.






Se usa para conteos de ocurrencias en un intervalo de tiempo, espacio o área.

$$X \sim \text{Poi}(\lambda), \quad \mathbb{P}(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}.$$

- λ : tasa promedio de ocurrencias en el intervalo.
- $x = 0, 1, 2, \dots$




Ejemplos típicos Poisson



- Número de llamadas por hora en un call center.
- Número de fallas por semana en una máquina.
- Número de defectos por metro de tela.
- Número de accidentes menores por mes.

Supuestos aproximados

Eventos raros, tasa promedio estable e independencia en intervalos separados.



Ejemplo Poisson



Un equipo presenta en promedio $\lambda = 2$ fallas menores por semana. Probabilidad de observar exactamente 3 fallas en una semana:

$$\mathbb{P}(X = 3) = \frac{e^{-2}2^3}{3!} = 0.180.$$

Probabilidad de ninguna falla:

$$\mathbb{P}(X = 0) = e^{-2} = 0.135.$$





Tabla de selección de modelos



Situación	Modelo	Parámetros
Éxito/fracaso único	Bernoulli	p
Conteo de éxitos en n ensayos	Binomial	n, p
Ensayos hasta primer éxito	Geométrica	p
Ensayos hasta r éxitos	Pascal	r, p
Muestreo sin reemplazo	Hipergeométrica	N, K, n
Conteos por intervalo	Poisson	λ




Ejercicio integrado



Seleccione el modelo apropiado y calcule:

1. Un lote tiene 8 % de piezas defectuosas. Se inspeccionan 12 piezas con independencia aproximada. Probabilidad de exactamente 2 defectuosas.
2. Un call center recibe en promedio 5 llamadas por hora. Probabilidad de recibir 0 llamadas en una hora.





1. **Binomial:** $X \sim \text{Bin}(12, 0.08)$.


$$\mathbb{P}(X = 2) = \binom{12}{2} (0.08)^2 (0.92)^{10} = 0.147.$$

2. **Poisson:** $Y \sim \text{Poi}(5)$.

$$\mathbb{P}(Y = 0) = \frac{e^{-5} 5^0}{0!} = e^{-5} = 0.0067.$$

Lectura


Es poco probable una hora sin llamadas si el promedio histórico es 5 por hora.



Errores frecuentes



- Usar binomial cuando no hay independencia ni probabilidad constante.
- Usar Poisson sin identificar claramente el intervalo de tiempo o espacio.
- Confundir geométrica con binomial: una cuenta ensayos hasta el éxito, la otra éxitos en ensayos fijos.
- Ignorar que la hipergeométrica aplica a muestreo sin reemplazo.






- Los modelos discretos representan conteos y eventos sí/no.
- La selección del modelo depende del mecanismo del proceso.
- Los parámetros tienen interpretación operacional.
- Siempre se deben revisar supuestos antes de usar una fórmula.

Conexión

La siguiente clase introduce modelos continuos para tiempos, pesos, dimensiones y mediciones.




Mapa del curso



INGENIERÍA
INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso
2. Conceptos básicos de probabilidad
3. Bayes, variables aleatorias y distribuciones
4. Esperanza, varianza y desviación estándar
5. Modelos probabilísticos discretos
6. Modelos probabilísticos continuos
 - 6.1 Uniforme y Exponencial
 - 6.2 Normal
 - 6.3 Otras distribuciones y ejercicios
7. Conceptos básicos de estadística
8. Propiedades de estimadores y Teorema Central del Límite
9. Intervalos de confianza e introducción a hipótesis
10. Pruebas de hipótesis paramétricas
11. Pruebas para muestras pareadas






Muchas variables industriales no son conteos, sino mediciones:

- tiempo de atención
- peso de un producto
- diámetro de una pieza
- duración hasta una falla
- temperatura de operación

Idea


Los modelos continuos permiten asignar probabilidades a intervalos de valores.



Objetivos



1. Interpretar densidades y probabilidades como áreas.
2. Usar los modelos Uniforme, Exponencial y Normal.
3. Calcular probabilidades en intervalos.
4. Reconocer aplicaciones industriales de cada modelo.





Para una variable continua X :


$$\mathbb{P}(a \leq X \leq b) = \int_a^b f(x) dx.$$

Importante

Para variables continuas, $\mathbb{P}(X = c) = 0$ para un punto exacto c .

Interpretación

La probabilidad de que un tiempo de servicio esté entre 4 y 6 minutos es el área bajo la densidad entre 4 y 6.



Distribución Uniforme




Si todos los valores en $[a, b]$ son igualmente plausibles:

$$X \sim \text{Unif}(a, b).$$

$$f(x) = \frac{1}{b-a}, \quad a \leq x \leq b.$$

$$\mathbb{E}[X] = \frac{a+b}{2}, \quad \text{Var}(X) = \frac{(b-a)^2}{12}.$$



Ejemplo Uniforme




Un camión puede llegar en cualquier momento entre las 8:00 y las 10:00. Sea X el tiempo de llegada medido en horas después de las 8:00:

$$X \sim \text{Unif}(0, 2).$$

Probabilidad de que llegue antes de las 8:45:

$$\mathbb{P}(X \leq 0.75) = \frac{0.75 - 0}{2 - 0} = 0.375.$$



Distribución Exponencial




Se usa para modelar tiempos hasta la ocurrencia de un evento.

$$X \sim \text{Exp}(\lambda), \quad f(x) = \lambda e^{-\lambda x}, \quad x \geq 0.$$

$$F(x) = 1 - e^{-\lambda x}.$$

$$\mathbb{E}[X] = \frac{1}{\lambda}, \quad \text{Var}(X) = \frac{1}{\lambda^2}.$$




Aplicaciones Exponencial



- tiempo hasta la próxima llamada
- tiempo hasta falla de un componente
- tiempo entre llegadas de clientes
- duración de una tarea sencilla bajo cierta memoria limitada

Interpretación de λ

λ es una tasa promedio de ocurrencia por unidad de tiempo.



Ejemplo Exponencial




El tiempo hasta la próxima falla de un sensor sigue aproximadamente una exponencial con tasa $\lambda = 0.25$ fallas por mes.

- Tiempo promedio hasta falla: $1/0.25 = 4$ meses.

Probabilidad de falla antes de 2 meses:

$$\mathbb{P}(X \leq 2) = 1 - e^{-0.25(2)} = 1 - e^{-0.5} = 0.393.$$






La Normal es uno de los modelos continuos más usados.

$$X \sim \mathcal{N}(\mu, \sigma^2).$$

- μ : media o centro de la distribución.
- σ : desviación estándar.
- Curva simétrica y con forma de campana.

Aplicaciones

Dimensiones de piezas, errores de medición, promedios muestrales y variabilidad natural de procesos.





Para calcular probabilidades normales se usa:


$$Z = \frac{X - \mu}{\sigma}.$$

Entonces:

$$Z \sim \mathcal{N}(0, 1).$$

Interpretación

Z mide cuántas desviaciones estándar está X por sobre o bajo la media.



Ejemplo Normal: diámetro de piezas




El diámetro de una pieza se modela como:

$$X \sim \mathcal{N}(50, 0.2^2) \text{ mm.}$$

¿Cuál es la probabilidad de que $X \leq 50.3$?

$$Z = \frac{50.3 - 50}{0.2} = 1.5.$$

$$\mathbb{P}(X \leq 50.3) = \mathbb{P}(Z \leq 1.5) \approx 0.9332.$$



Intervalos típicos de la Normal




Aproximadamente:

- 68 % de los valores cae entre $\mu \pm 1\sigma$.
- 95 % cae entre $\mu \pm 2\sigma$.
- 99.7 % cae entre $\mu \pm 3\sigma$.

Uso industrial

Esta regla es útil para control de procesos y detección inicial de observaciones inusuales.






Si el diámetro debe estar entre 49.6 y 50.4 mm, y $X \sim \mathcal{N}(50, 0.2^2)$:

$$\mathbb{P}(49.6 \leq X \leq 50.4) = \mathbb{P}(-2 \leq Z \leq 2) \approx 0.9545.$$

Interpretación

Aproximadamente 95.45 % de las piezas caen dentro de especificación si el modelo es adecuado.




Otras distribuciones introductorias



- **Gamma:** tiempos acumulados hasta varios eventos.
- **Weibull:** confiabilidad y vida útil de componentes.
- **Lognormal:** tiempos o costos positivos con asimetría.
- **Beta:** proporciones entre 0 y 1.

Idea práctica

No todos los procesos continuos son normales. La forma de los datos debe orientar el modelo.




Ejercicio propuesto



El tiempo de reparación de un equipo sigue una distribución exponencial con media 5 horas.

1. Identifique λ .
2. Calcule la probabilidad de reparar antes de 3 horas.

Además, una dimensión $X \sim \mathcal{N}(100, 2^2)$. Calcule $\mathbb{P}(X > 103)$.





Como $\mathbb{E}[X] = 1/\lambda = 5$:


$$\lambda = 0.2.$$

$$\mathbb{P}(X \leq 3) = 1 - e^{-0.2(3)} = 1 - e^{-0.6} = 0.451.$$

Para $X \sim \mathcal{N}(100, 2^2)$:

$$Z = \frac{103 - 100}{2} = 1.5.$$

$$\mathbb{P}(X > 103) = 1 - \mathbb{P}(Z \leq 1.5) = 1 - 0.9332 = 0.0668.$$






- Las probabilidades continuas se calculan como áreas bajo una densidad.
- Uniforme representa incertidumbre homogénea en un intervalo.
- Exponencial modela tiempos hasta un evento.
- Normal modela variabilidad simétrica alrededor de una media.
- La estandarización convierte una Normal general en Normal estándar.

Conexión

Pasaremos desde modelos probabilísticos a estadística: cómo aprender desde muestras reales.



Mapa del curso



INGENIERÍA
INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso
2. Conceptos básicos de probabilidad
3. Bayes, variables aleatorias y distribuciones
4. Esperanza, varianza y desviación estándar
5. Modelos probabilísticos discretos
6. Modelos probabilísticos continuos
7. Conceptos básicos de estadística
 - 7.1 Censo, población y muestra aleatoria
 - 7.2 Parámetros, estadísticos y estimadores
 - 7.3 Medidas muestrales básicas
 - 7.4 Criterios para seleccionar un buen estimador
 - 7.5 Tipos de estimación
 - 7.6 Ejemplo integrador y cierre
8. Propiedades de estimadores y Teorema Central del Límite
9. Intervalos de confianza e introducción a hipótesis
10. Pruebas de hipótesis paramétricas
11. Pruebas para muestras pareadas



Motivación: de la población a la evidencia





Pregunta industrial

Una empresa fabrica miles de piezas por semana.

¿Es necesario revisar todas para estimar la calidad?

Idea central

La estadística permite aprender sobre una población usando información parcial.




Definición

La **población** es el conjunto completo de unidades sobre las cuales se desea concluir.

Ejemplos en ingeniería

- Todas las piezas fabricadas en un mes.
- Todos los tiempos de atención de una sucursal.
- Todos los pedidos recibidos por una empresa.
- Todos los clientes activos de una plataforma.




Practiquemos !



Ejercicio 1.

Una universidad quiere estudiar la duración real de las prácticas profesionales de sus estudiantes de Ingeniería Industrial durante 2026.

1. ¿Cuál es la población?
2. ¿La población está compuesta por personas, prácticas o duraciones?
3. ¿Qué variable se desea observar?



Definición


Un **censo** ocurre cuando se observa o mide a todos los elementos de la población.

Ventaja

No hay error por muestreo, porque no se observa una parte, sino el total.

Limitación

Puede ser costoso, lento, inviable o destructivo.



Conjunto total de interés






Ejercicio 2.

Una empresa tiene 120 máquinas y registra el consumo eléctrico mensual de cada una.

1. ¿Se realizó un censo o un muestreo?
2. ¿Qué ventaja tiene este procedimiento?
3. ¿Qué problema aparecería si fueran 120.000 máquinas distribuidas en todo el país?




Definición

Una **muestra** es una parte o subconjunto de la población seleccionado para ser observado.

¿Por qué muestrear?

- Reduce costos.
- Acelera el análisis.
- Evita mediciones destructivas.
- Permite tomar decisiones oportunas.






Ejercicio 3.

Una empresa fabrica 50.000 botellas. Se seleccionan 300 para controlar el volumen de llenado.

1. Identifique población y muestra.
2. ¿Por qué no sería eficiente medir todas las botellas?
3. ¿Qué riesgo aparece al trabajar con una muestra?




Definición

Una **muestra aleatoria** es una muestra seleccionada mediante un mecanismo donde las unidades tienen una probabilidad conocida de ser elegidas.

Muestreo aleatorio simple

Cada elemento de la población tiene la misma oportunidad de ser incluido en la muestra.






Ejercicio 4.

Una bodega tiene 1.000 cajas numeradas. Se deben seleccionar 20 para inspección.

1. Proponga un procedimiento para seleccionar una muestra aleatoria simple.
2. ¿Qué problema ocurre si solo se eligen las cajas más cercanas a la puerta?
3. ¿La muestra sería representativa?



Condiciones deseables de una muestra



Homogeneidad

Las observaciones deben provenir de la misma población objetivo.


Independencia

Una observación no debe determinar artificialmente el valor de otra.


Representatividad

La muestra debe reflejar adecuadamente la diversidad de la población.

Buena muestra



Refleja grupos relevantes






Ejercicio 5.

Se desea estimar la satisfacción de los clientes de una empresa. La encuesta se aplica solo a quienes visitan la sucursal entre 9:00 y 10:00.

1. ¿Qué condición puede fallar?
2. ¿Qué grupo podría quedar subrepresentado?
3. Proponga una mejora al diseño muestral.





Definición

Un **parámetro** es una cantidad numérica que describe una característica de la población.

- Media poblacional: μ .
- Varianza poblacional: σ^2 .
- Desviación estándar poblacional: σ .
- Proporción poblacional: p .

Clave

El parámetro es fijo, pero normalmente desconocido.






Ejercicio 6.

En una línea de producción, se quiere conocer la proporción real de piezas defectuosas producidas durante mayo.

1. ¿Cuál es el parámetro de interés?
2. ¿Es conocido o desconocido antes de medir?
3. ¿Por qué no cambia de muestra en muestra?



Definición


Un **estadístico** es una cantidad calculada usando los datos de una muestra.

- Media muestral: $\bar{X}$.
- Varianza muestral: S^2 .
- Desviación estándar muestral: S .
- Proporción muestral: $\hat{p}$.


Clave

Cambia de muestra en muestra; por eso es una variable aleatoria.

Muestra



$\bar{X}$, S^2 , $\hat{p}$






Ejercicio 7.

Se observan los tiempos de atención de 5 clientes:

8, 10, 7, 12, 13.

1. Calcule la media muestral.
2. Explique por qué ese valor es un estadístico.
3. ¿Ese valor sería necesariamente igual si se eligieran otros 5 clientes?



Parámetro versus estadístico



Concepto	Población	Muestra
Cantidad	Parámetro	Estadístico
Media	μ	$\bar{X}$
Varianza	σ^2	S^2
Desviación estándar	σ	S
Proporción	p	$\hat{p}$
Tamaño	N	n

Población

Contiene el valor real de interés.

$$\mu, \sigma^2, p$$

Muestra

Entrega evidencia parcial.

$$\bar{X}, S^2, \hat{p}$$






Ejercicio 8.

Clasifique cada cantidad como parámetro o estadístico:

1. El promedio real de espera de todos los clientes.
2. El promedio de espera calculado con 50 clientes.
3. La proporción real de pedidos atrasados.
4. La proporción observada de atrasos en una muestra de 200 pedidos.



Definición

Un **estimador** es una regla, fórmula o estadístico usado para aproximar un parámetro desconocido.

Ejemplos


$\bar{X}$ estima a μ

S^2 estima a σ^2

$\hat{p}$ estima a p

Idea

El estimador es la regla antes de observar los datos.






Ejercicio 9.

Para estimar el gasto promedio mensual de los clientes de una tienda:

1. ¿Cuál es el parámetro?
2. ¿Qué estimador usaría?
3. ¿Qué datos necesita observar?



Definición

Una **estimación** es el valor numérico obtenido al aplicar un estimador a una muestra concreta.

Ejemplo

Si los tiempos observados son:

8, 10, 7, 12, 13,

entonces:


$$\bar{x} = \frac{8 + 10 + 7 + 12 + 13}{5} = 10.$$

Estimador
 $\bar{X}$



Estimación
 $\bar{x} = 10$

Regla versus
valor observado






Ejercicio 10.

En una muestra de 80 productos, 6 presentan defectos.

1. Identifique el estimador.
2. Calcule la estimación.
3. Interprete el resultado en contexto.





Definición

La **media muestral** resume el centro de los datos observados.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Interpretación

Representa un valor promedio observado en la muestra y se usa frecuentemente para estimar μ .






Ejercicio 11.

Los tiempos de reparación de 6 equipos son:

14, 18, 16, 20, 15, 19.

1. Calcule $\bar{x}$.
2. Interprete el resultado.
3. ¿Qué parámetro intenta aproximar?





Definición

Cuando la variable es dicotómica, la **proporción muestral** es:

$$\hat{p} = \frac{\text{número de éxitos en la muestra}}{n}.$$


Ejemplo

Si se inspeccionan 100 pedidos y 12 llegan atrasados:

$$\hat{p} = \frac{12}{100} = 0.12.$$



Éxitos / total






Ejercicio 12.

De 250 facturas revisadas, 18 tienen errores.

1. Calcule $\hat{p}$.
2. ¿Qué representa un “éxito” en este contexto?
3. ¿Qué parámetro se quiere estimar?



Propósito

Estas medidas resumen el comportamiento central de un conjunto de datos.

Media

Promedio aritmético.

$$\bar{x}$$

Mediana



Valor central al ordenar los datos.

$$Me$$

Moda

Valor más frecuente.


$$Mo$$



Idea

La **asimetría** describe hacia qué lado se extiende la cola de una distribución.


Asimetría positiva



$$Mo < Me < \bar{x}$$

Cola hacia la derecha

Asimetría negativa



$$Mo > Me > \bar{x}$$

Cola hacia la izquierda




Curtosis: forma de la distribución



Idea

La **curtosis** describe qué tan concentrados están los datos alrededor del centro y qué tan pronunciadas son las colas de la distribución.


Leptocúrtica



Más apuntada

Curtosis alta


Mesocúrtica



Similar a la normal


Curtosis media

Platicúrtica



Más plana

Curtosis baja






Ejercicio 13.

Para los datos:

84, 91, 72, 68, 87, 78, 65, 87, 79,

calcule:

1. Media.
2. Mediana.
3. Moda.
4. ¿Cuál medida resume mejor el centro de estos datos?



¿Qué hace bueno a un estimador?



Problema



No todo estadístico es igualmente útil para estimar un parámetro.

- Insesgamiento.
- Eficiencia.
- Consistencia.
- Suficiencia.

Idea central

Un buen estimador debe acercarse al parámetro con poco error y buena estabilidad.

Distribución del estimador






Ejercicio 14.

Imagine dos métodos para estimar el tiempo promedio de despacho:



- Método A produce resultados muy variables.
 - Método B produce resultados más estables.
1. ¿Qué método parece preferible?
 2. ¿Qué criterio de buen estimador se relaciona con esta comparación?



Definición intuitiva

Un estimador es **insesgado** si, al repetir muchas muestras, su valor promedio coincide con el parámetro que busca estimar.

$$E(\hat{\theta}) = \theta.$$






Ejercicio 15.

Un sensor de temperatura siempre mide, en promedio, 2 grados más que la temperatura real.




1. ¿El sensor entrega una estimación sesgada o insesgada?
2. ¿Qué efecto tendría esto al estimar la temperatura promedio?
3. ¿Cómo podría corregirse el problema?





Definición intuitiva

Entre dos estimadores insesgados, es más **eficiente** el que tiene menor variabilidad.






Ejercicio 16.

Dos métodos estiman el peso promedio de cajas:

- Método A: errores típicos cercanos a 0.5 kg.
- Método B: errores típicos cercanos a 2 kg.

1. ¿Cuál método es más eficiente?
2. ¿Por qué una menor variabilidad es deseable?



Definición intuitiva



Un estimador es **consistente** si se aproxima cada vez más al parámetro cuando aumenta el tamaño muestral.

Idea

Más datos bien recolectados deberían producir estimaciones más confiables.

Ejemplo

La media muestral suele acercarse a la media poblacional cuando n crece.






Ejercicio 17.

Se estima el tiempo promedio de espera con muestras de tamaño 5, 30 y 200.

1. ¿Cuál estimación esperarías que fuera más estable?
2. ¿Qué criterio de buen estimador aparece en esta situación?
3. ¿Por qué aumentar n no corrige necesariamente una muestra mal seleccionada?



Definición intuitiva



Un estimador es **suficiente** si utiliza toda la información relevante de la muestra para inferir el parámetro.

Interpretación

No debería desperdiciar información útil contenida en los datos.

Idea práctica

Un estimador suficiente resume la muestra sin perder información relevante sobre el parámetro.






Ejercicio 18.

Para estimar el promedio de producción diaria, un analista usa solo el valor máximo observado.

1. ¿Parece usar toda la información relevante?
2. ¿Qué estadístico sería más razonable?
3. ¿Qué información se pierde al usar solo el máximo?



Definición


Una **estimación puntual** entrega un único valor para aproximar un parámetro desconocido.

Ejemplo


Si se inspeccionan 200 piezas y 9 son defectuosas:

$$\hat{p} = \frac{9}{200} = 0.045.$$

La estimación puntual de p es 4.5 %.



Un solo valor






Ejercicio 19.

En 60 pedidos, 51 llegaron a tiempo.

1. Calcule la estimación puntual de la proporción de pedidos a tiempo.
2. Interprete el resultado.
3. ¿Qué información sobre incertidumbre falta?



Definición


Una **estimación por intervalo** entrega un rango plausible de valores para el parámetro.

Interpretación

Reconoce explícitamente que existe incertidumbre muestral.

Forma general

Estimación puntual $\pm$ margen de error.






Ejercicio 20.

Una empresa estima que el tiempo promedio de despacho está entre 3.8 y 4.6 días.

1. ¿Cuál es la estimación por intervalo?
2. ¿Cuál podría ser una estimación puntual razonable?
3. ¿Por qué el intervalo comunica más información que un solo número?





Ejemplo integrador: control de calidad



Una empresa fabrica 10.000 piezas durante una semana. Se seleccionan aleatoriamente 200 piezas y 9 son defectuosas.

Identificación

- Población: 10.000 piezas.
- Muestra: 200 piezas seleccionadas.
- Parámetro: proporción real p .
- Estadístico: $\hat{p}$.
- Estimación: $\hat{p} = 9/200 = 0.045$.




Practiquemos !



Ejercicio 21.

Una empresa fabrica 10.000 piezas durante una semana. Se seleccionan aleatoriamente 200 piezas y 9 son defectuosas.

1. Identifique población y muestra.
2. Identifique parámetro, estadístico, estimador y estimación.
3. ¿La empresa debería concluir que exactamente 4.5 % de toda la producción es defectuosa?



Resumen de conceptos básicos



Concepto	Idea central
Población	Conjunto total de interés
Censo	Medición de todos los elementos
Muestra	Subconjunto observado
Muestra aleatoria	Selección con mecanismo aleatorio
Parámetro	Característica numérica poblacional
Estadístico	Cantidad calculada desde la muestra
Estimador	Regla para aproximar un parámetro
Estimación	Valor observado del estimador
Estimación puntual	Un valor aproximado
Estimación por intervalo	Rango plausible de valores

Conexión

Estos conceptos permiten pasar de datos observados a conclusiones estadísticas sobre una población.


Mapa del curso



INGENIERÍA
INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso
2. Conceptos básicos de probabilidad
3. Bayes, variables aleatorias y distribuciones
4. Esperanza, varianza y desviación estándar
5. Modelos probabilísticos discretos
6. Modelos probabilísticos continuos
7. Conceptos básicos de estadística
8. Propiedades de estimadores y Teorema Central del Límite
 - 8.1 Motivación y objetivo inferencial
 - 8.2 Sesgo, varianza y error cuadrático medio
 - 8.3 Consistencia, eficiencia y suficiencia
 - 8.4 Distribución muestral y error estándar
 - 8.5 Teorema Central del Límite
 - 8.6 Ejercicios integradores y cierre
9. Intervalos de confianza e introducción a hipótesis
10. Pruebas de hipótesis paramétricas
11. Pruebas de hipótesis no paramétricas



Motivación: estimar no es suficiente




Pregunta industrial

Dos analistas estiman el tiempo promedio de producción usando muestras distintas:


$$\bar{x}_A = 12.1 \quad \text{y} \quad \bar{x}_B = 15.8.$$

¿Cuál estimación deberíamos confiar más?



Idea central



No basta con obtener un número: necesitamos evaluar la **calidad del estimador**.




Objetivos de la sección



1. Comprender sesgo, varianza y error cuadrático medio.
2. Interpretar consistencia, eficiencia y suficiencia.
3. Comprender la distribución muestral de un estadístico.
4. Interpretar el error estándar de la media muestral.
5. Entender la importancia del Teorema Central del Límite.



Mapa conceptual de la sección




Definición

El **sesgo** mide si un estimador acierta en promedio al parámetro.

$$\text{Sesgo}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta.$$

Interpretación


- Si $\text{Sesgo}(\hat{\theta}) = 0$, el estimador es insesgado.
- Si $\text{Sesgo}(\hat{\theta}) > 0$, tiende a sobreestimar.
- Si $\text{Sesgo}(\hat{\theta}) < 0$, tiende a subestimar.



Sesgo: tiro al blanco




Estimador insesgado



Parámetro real


Estimador sesgado



Parámetro real

Lectura visual

Un estimador insesgado no necesariamente acierta siempre, pero sus estimaciones se centran alrededor del valor real.






Ejercicio 1.

Una balanza industrial presenta sistemáticamente un error de $+2$ kg respecto del peso real.


1. ¿Existe sesgo?
2. ¿La balanza sobreestima o subestima el peso?
3. ¿El problema desaparece tomando más observaciones?
4. ¿Qué acción correctiva propondría antes de usar los datos para tomar decisiones?




Idea

Un estimador cambia de una muestra a otra. La **varianza del estimador** mide qué tan inestable es entre muestras posibles.

Baja varianza




Alta varianza




Interpretación industrial

Menor varianza significa estimaciones más estables y decisiones menos dependientes de la muestra específica observada.

Varianza: precisión versus dispersión




Preciso



Impreciso

Clave

La varianza no mide si el estimador está centrado; mide qué tan dispersas son sus estimaciones.






Ejercicio 2.

Dos métodos estiman el peso promedio de cajas usando muestras del mismo tamaño.

- Método A: sus estimaciones fluctúan típicamente entre 99.5 y 100.5 kg.
- Método B: sus estimaciones fluctúan típicamente entre 96 y 104 kg.

1. ¿Cuál método tiene menor varianza?
2. ¿Cuál entregaría decisiones más estables?
3. ¿Puede un método tener baja varianza y aun así estar sesgado?




Definición

El **error cuadrático medio** mide el error promedio cuadrático entre el estimador y el parámetro.

$$ECM(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2].$$

Descomposición fundamental


$$ECM(\hat{\theta}) = \text{Var}(\hat{\theta}) + \text{Sesgo}(\hat{\theta})^2.$$




ECM: cuatro situaciones posibles




Bajo sesgo, baja varianza




Alto sesgo, baja varianza



Bajo sesgo, alta varianza



Alto sesgo, alta varianza



Lectura

Un estimador puede fallar por estar desplazado, por ser muy variable o por ambas razones.




Practiquemos !



Ejercicio 3.

Un estimador A tiene varianza 9 y sesgo 1. Un estimador B tiene varianza 4 y sesgo 2.

1. Calcule el *ECM* de cada estimador.
2. ¿Cuál tiene menor error cuadrático medio?
3. ¿Cuál elegiría si el objetivo es minimizar error total?



Definición intuitiva



Un estimador es **consistente** si se aproxima al parámetro real cuando aumenta el tamaño muestral.

Idea




Más datos bien recolectados deberían producir estimaciones más confiables.

Ejemplo

La media muestral $\bar{X}$ suele acercarse a la media poblacional μ cuando n crece.




Consistencia: efecto del tamaño muestral



Interpretación

Al aumentar n , la distribución del estimador se concentra alrededor del parámetro.






Ejercicio 4.



Se estima el tiempo promedio de espera con muestras de tamaño 5, 30 y 200.

1. ¿Cuál estimación esperarías que fuera más estable?
2. ¿Qué propiedad del estimador aparece en esta situación?
3. ¿Por qué aumentar n no corrige necesariamente una muestra mal seleccionada?



Definición

Entre estimadores insesgados, uno es más **eficiente** si tiene menor varianza.



Interpretación industrial

Un estimador eficiente entrega decisiones más estables usando la misma cantidad de datos.






Ejercicio 5.

Dos estimadores inesgados se usan para estimar el costo promedio mensual de mantenimiento.

- Estimador A: desviación estándar de sus estimaciones igual a 20 dólares.
 - Estimador B: desviación estándar de sus estimaciones igual a 35 dólares.
1. ¿Cuál estimador es más eficiente?
 2. ¿Por qué la eficiencia importa si ambos son inesgados?
 3. ¿Qué estimador preferiría para presupuestar costos?



Definición intuitiva


Un estimador es **suficiente** si resume toda la información relevante de la muestra para inferir el parámetro.

Idea práctica

No debería desperdiciar información útil contenida en los datos.

Ejemplo conceptual

Para estimar un promedio, usar todos los datos suele ser más informativo que usar solo el valor máximo o mínimo.






Ejercicio 6.

Para estimar el promedio de producción diaria, un analista usa solo el valor máximo observado en la muestra.

1. ¿Parece usar toda la información relevante?
2. ¿Qué estadístico sería más razonable para estimar el promedio?
3. ¿Qué información se pierde al usar solo el máximo?





¿Qué ocurre si repetimos el muestreo?



Experimento mental

Tomamos muchas muestras del mismo tamaño desde la misma población y calculamos una media en cada una.

$$\bar{x}_1 = 19.8, \quad \bar{x}_2 = 20.4, \quad \bar{x}_3 = 19.2, \dots$$







Definición informal

La **distribución muestral** describe los valores que podría tomar un estadístico en muchas muestras repetidas.

Ejemplo

Si el estadístico es la media muestral, la distribución muestral describe cómo varía $\bar{X}$ de muestra en muestra.





Si $X_1, \dots, X_n$ son observaciones independientes con media μ y desviación estándar σ :


$$\mathbb{E}[\bar{X}] = \mu, \quad (\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

Centro

La media muestral está centrada en la media poblacional.

Dispersión

La dispersión de $\bar{X}$ disminuye cuando aumenta n .





Definición

El **error estándar** es la desviación estándar de la distribución muestral de un estadístico.


Para la media muestral:

$$(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

Interpretación

Mide la variabilidad típica de la media muestral alrededor de μ .

n	$= \sigma / \sqrt{n}$ con $\sigma = 6$
9	2.00
36	1.00
144	0.50




Idea

Aumentar el tamaño muestral reduce el error estándar, pero no de forma lineal.

$$(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

- Duplicar n no reduce el error a la mitad.
- Para reducir el error a la mitad, se requiere aproximadamente cuadruplicar n .






Ejercicio 7.

El tiempo de atención tiene desviación estándar histórica $\sigma = 6$ minutos.

1. Calcule el error estándar de $\bar{X}$ si $n = 9$.
2. Calcule el error estándar de $\bar{X}$ si $n = 36$.
3. ¿Qué ocurre con la precisión al aumentar el tamaño muestral?





Teorema Central del Límite: intuición



Idea sin demostración

Para muestras suficientemente grandes, la distribución de $\bar{X}$ se aproxima a una Normal, incluso si los datos originales no son normales.

$$\bar{X} \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$



TCL: datos originales no normales





Situación

La variable original puede ser asimétrica, discreta o tener una forma irregular.

Mensaje



El TCL no dice que los datos originales sean normales. Dice que las **medias muestrales** se aproximan a una Normal.





Muestras pequeñas



Con n pequeño, la distribución de $\bar{X}$ puede conservar parte de la forma irregular de la población original.








Muestras grandes

Al aumentar n , la distribución de $\bar{X}$ se vuelve más simétrica, más concentrada y más parecida a una Normal.






Variable original

 $\bar{X}, n = 5$  $\bar{X}, n = 30$ 

Mensaje clave

El TCL transforma el problema: aunque los datos no sean normales, las medias muestrales pueden analizarse con aproximaciones normales.






Ejercicio 8.

Una empresa registra tiempos de espera muy asimétricos: la mayoría de los clientes espera poco, pero algunos esperan mucho.

1. ¿Los datos originales parecen normales?
2. Si se toman muchas muestras grandes y se calcula $\bar{X}$, ¿qué forma aproximada tendría la distribución de esas medias?
3. ¿Qué teorema justifica esta aproximación?






Si $X_1, \dots, X_n$ son independientes con media μ y desviación estándar σ , entonces para n suficientemente grande:

$$\bar{X} \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Estandarización

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \approx \mathcal{N}(0, 1).$$



Ejemplo: tiempo promedio de atención





Suponga que el tiempo de atención tiene desviación estándar $\sigma = 6$ minutos. Se toma una muestra de $n = 36$ clientes.

$$(\bar{X}) = \frac{6}{\sqrt{36}} = 1 \text{ minuto.}$$

Interpretación

La media muestral fluctúa típicamente alrededor de la media real con una escala de 1 minuto.



Ejemplo: probabilidad usando TCL




Si $\mu = 20$, $\sigma = 6$ y $n = 36$, entonces:

$$\bar{X} \approx \mathcal{N}(20, 1^2).$$


Probabilidad de que la media muestral supere 21.5:

$$Z = \frac{21.5 - 20}{1} = 1.5.$$

$$\mathbb{P}(\bar{X} > 21.5) = \mathbb{P}(Z > 1.5) = 1 - 0.9332 = 0.0668.$$




Ejemplo: región de cola



Interpretación

Una media muestral mayor que 21.5 sería poco frecuente si la media real fuera 20 y $\sigma = 6$.






Ejercicio 9.

El peso de cajas producidas tiene media desconocida y desviación estándar histórica $\sigma = 4$ kg. Se toma una muestra de $n = 64$ cajas.

1. Calcule el error estándar de $\bar{X}$.
2. Si la media real fuera 100 kg, aproxime $\mathbb{P}(\bar{X} > 101)$.
3. Interprete el resultado en contexto.






Ejercicio 10.

Una empresa compara dos diseños muestrales para estimar la satisfacción promedio de clientes.


- Diseño A: encuesta solo clientes de la mañana, con $n = 200$.
 - Diseño B: encuesta clientes de mañana, tarde y noche, con $n = 80$.
1. ¿Cuál podría tener menor error estándar?
 2. ¿Cuál podría ser más representativo?
 3. ¿Por qué una muestra grande no garantiza una buena estimación?



Resumen de la sección



Concepto	Idea central
Sesgo	Error sistemático respecto del parámetro
Varianza	Inestabilidad entre muestras posibles
ECM	Error total: varianza más sesgo al cuadrado
Consistencia	El estimador mejora al aumentar n
Eficiencia	Menor varianza entre estimadores comparables
Suficiencia	Uso de toda la información relevante
Distribución muestral	Distribución de un estadístico en muestras repetidas
Error estándar	Variabilidad típica del estimador
TCL	Normalidad aproximada de medias muestrales




Conexión con la próxima sección




Idea final

El Teorema Central del Límite permite transformar una estimación puntual en una afirmación con incertidumbre cuantificada.



Próximo paso

Usaremos estas ideas para construir **intervalos de confianza** para medias y proporciones.




Mapa del curso



INGENIERÍA
INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso
2. Conceptos básicos de probabilidad
3. Bayes, variables aleatorias y distribuciones
4. Esperanza, varianza y desviación estándar
5. Modelos probabilísticos discretos
6. Modelos probabilísticos continuos
7. Conceptos básicos de estadística
8. Propiedades de estimadores y Teorema Central del Límite
- 9. Intervalos de confianza e introducción a hipótesis**
 - 9.1 Intervalos de confianza
 - 9.2 Introducción a pruebas de hipótesis
 - 9.3 Cierre
10. Pruebas de hipótesis paramétricas
11. Pruebas para muestras no paramétricas



Motivación: una estimación puntual no basta



Una estimación puntual rara vez es suficiente.

Pregunta industrial

Si estimamos que el tiempo promedio de atención es:

$$\bar{x} = 12.4 \text{ minutos,}$$

¿qué tan precisa es esa estimación?

Estimación puntual

Entrega un solo número.

12.4

Intervalo de confianza

Entrega un rango plausible.

[11.6, 13.2]




Dos muestras, dos respuestas




Muestra A

$$n = 40, \quad \bar{x} = 12.4$$




Muestra B

$$n = 40, \quad \bar{x} = 13.1$$



Idea

Diferentes muestras producen diferentes estimaciones. El intervalo de confianza intenta expresar esa incertidumbre.




Objetivos



1. Interpretar correctamente intervalos de confianza.
2. Construir intervalos para una media y una proporción.
3. Comprender el rol del margen de error.
4. Introducir hipótesis nula y alternativa.
5. Comprender nivel de significancia, errores Tipo I/II y valor-p.

Enfoque

No solo interesa calcular intervalos o valores-p. Lo importante es interpretar qué significan para una decisión.




Idea de intervalo de confianza




Un intervalo de confianza tiene la forma:

estimación $\pm$ margen de error.



Lectura

El intervalo combina una estimación puntual con una medida de precisión.



¿De qué depende el margen de error?



Margen de error = valor crítico $\times$ error estándar.

Variabilidad


Mayor variabilidad implica intervalos más anchos.

Tamaño muestral

Mayor n implica menor error estándar.

Confianza



Mayor confianza implica intervalos más anchos.





Interpretación correcta

Un 95 % de confianza se refiere al método: si repitiéramos muchas muestras y construyéramos intervalos de la misma forma, aproximadamente 95 % de esos intervalos contendrían al parámetro real.



Interpretaciones incorrectas frecuentes



Incorrecto


“Hay 95 % de probabilidad de que μ esté dentro de este intervalo”.

Correcto

El parámetro μ es fijo. El intervalo cambia de muestra en muestra. La confianza describe el desempeño del procedimiento de construcción.

Cuidado

Después de observar los datos, el intervalo calculado o contiene a μ o no lo contiene. La incertidumbre está en el procedimiento muestral, no en que μ se mueva.




Más datos, menor incertidumbre




Idea

Al aumentar el tamaño muestral, disminuye el error estándar y, por tanto, el intervalo tiende a ser más estrecho.



Misma variabilidad poblacional y misma confianza




Mayor confianza, mayor amplitud




Idea

Si exigimos mayor confianza, el intervalo debe ser más ancho.



Trade-off

Más confianza implica menos precisión aparente: el rango plausible se vuelve más amplio.



Tres ingredientes de un intervalo



1. Estimación

$$\bar{x}, \quad \hat{p}$$

Punto central del intervalo.

2. Error estándar

$$\frac{\sigma}{\sqrt{n}}, \quad \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$


Escala de incertidumbre.

3. Valor crítico

$$z_{\alpha/2}, \quad t_{\alpha/2, n-1}$$

Depende del nivel de confianza.

$$IC = \text{estimación} \pm \text{valor crítico} \times \text{error estándar.}$$



Intervalo para media con σ conocida




Si σ es conocida o histórica y n es suficientemente grande:

$$\bar{X} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}.$$

- $\bar{X}$: media muestral.
- $z_{\alpha/2}$: valor crítico Normal.
- $\sigma/\sqrt{n}$: error estándar.

Para 95 %

$$z_{\alpha/2} = z_{0.025} \approx 1.96.$$





¿De dónde sale 1.96?



Idea

En una Normal estándar, aproximadamente 95 % del área está entre -1.96 y 1.96 .



Ejemplo: tiempo de servicio



Se observa:

$$n = 64, \quad \bar{x} = 10.5, \quad \sigma = 4.$$


Intervalo 95 %:

$$10.5 \pm 1.96 \frac{4}{\sqrt{64}} = 10.5 \pm 1.96(0.5).$$

$$10.5 \pm 0.98 = (9.52, 11.48).$$

Interpretación

El método sugiere que la media real de atención está plausiblemente entre 9.52 y 11.48 minutos.






Ejercicio 1.

Se desea estimar el tiempo promedio de armado. En una muestra de $n = 49$ trabajadores se obtiene $\bar{x} = 32$ minutos. La desviación estándar histórica es $\sigma = 7$ minutos.

1. Construya un intervalo de confianza 95 % para μ .
2. Interprete el resultado.
3. ¿Qué ocurriría con la amplitud del intervalo si n aumentara a 196?



Intervalo para media con σ desconocida



Cuando σ no se conoce, usamos la desviación estándar muestral s y la distribución t :


$$\bar{X} \pm t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}.$$

Interpretación

La distribución t incorpora la incertidumbre adicional por estimar σ usando s .


Uso frecuente

Este caso es común en estudios reales, porque normalmente la desviación estándar poblacional no se conoce.




Idea

La distribución t tiene colas más pesadas que la Normal, especialmente con pocos grados de libertad.



La diferencia disminuye cuando n crece.





Para una proporción poblacional p :


$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

Aplicaciones

- Piezas defectuosas.
- Entregas atrasadas.
- Clientes insatisfechos.
- Pedidos con error documental.



Defectos / total



Ejemplo: proporción defectuosa



Se inspeccionan $n = 400$ piezas y 28 son defectuosas:

$$\hat{p} = \frac{28}{400} = 0.07.$$

Intervalo 95 %:

$$0.07 \pm 1.96 \sqrt{\frac{0.07(0.93)}{400}}.$$

$$0.07 \pm 0.025 = (0.045, 0.095).$$

Interpretación

La proporción real de defectuosas se estima entre 4.5 % y 9.5 %, usando un método con 95 % de confianza.






Ejercicio 2.

Una empresa revisa $n = 500$ pedidos y encuentra que 35 presentan errores de documentación.

1. Calcule $\hat{p}$.
2. Construya un intervalo de confianza 95 % para la proporción real de pedidos con error.
3. Interprete el resultado para el jefe de operaciones.



Errores comunes al interpretar intervalos



Error 1

Decir que el 95 % de los datos cae dentro del intervalo.

Error 2


Decir que hay 95 % de probabilidad de que el parámetro esté dentro del intervalo observado.

Error 3

Creer que un intervalo más ancho siempre es peor, sin considerar el nivel de confianza.

Lectura adecuada

El intervalo informa precisión de la estimación y debe interpretarse en contexto operacional.





Intervalo de confianza

Pregunta:


¿Qué valores son plausibles?

Prueba de hipótesis


Pregunta:

¿Hay evidencia contra una afirmación?

Estimación
con incertidumbre



Decisión
estadística





Una prueba de hipótesis contrasta una afirmación usando evidencia muestral.

H_0 : hipótesis nula


Representa el estado base, estándar, promesa o afirmación inicial.

H_1 : hipótesis alternativa

Representa cambio, diferencia, deterioro, mejora o efecto de interés.

Ejemplo

$$H_0 : \mu = 10 \quad \text{versus} \quad H_1 : \mu > 10.$$




Ejemplos industriales de hipótesis



Contexto	H_0	H_1
Tiempo de atención	$\mu = 10$	$\mu > 10$
Defectos	$p = 0.05$	$p > 0.05$
Despacho	$\mu = 48$	$\mu < 48$
Nuevo proceso	$\mu_{\text{nuevo}} = \mu_{\text{actual}}$	$\mu_{\text{nuevo}} < \mu_{\text{actual}}$

Interpretación

La hipótesis alternativa debe reflejar la pregunta de gestión o ingeniería.






Ejercicio 3.

Una empresa promete que el tiempo promedio de despacho es de 48 horas. El gerente sospecha que el promedio real es mayor.

1. Formule H_0 .
2. Formule H_1 .
3. Explique en palabras qué significaría rechazar H_0 .




Definición

El error Tipo I ocurre cuando se rechaza H_0 siendo H_0 verdadera.


Ejemplo en calidad

Se concluye que un proceso está fuera de control cuando en realidad funciona correctamente.



Lectura operacional

Es una falsa alarma estadística.




Definición

El error Tipo II ocurre cuando no se rechaza H_0 siendo H_0 falsa.


Ejemplo en calidad

No se detecta que la tasa de defectos aumentó, y se continúa operando como si el proceso estuviera bien.



Lectura operacional

Es una falla de detección.






El nivel de significancia α controla el riesgo de rechazar H_0 cuando H_0 es verdadera.

- Valores comunes: 0.10, 0.05, 0.01.
- Menor α exige evidencia más fuerte.
- α se fija antes de observar los datos.

Interpretación operacional



α representa la tolerancia al falso positivo estadístico.





Ejemplo unilateral a la derecha

Rechazamos H_0 si el estadístico cae demasiado lejos hacia la derecha.






Definición intuitiva

El valor-p mide qué tan compatible es la evidencia observada con H_0 .


- Valor-p pequeño: evidencia poco compatible con H_0 .
- Regla usual: si $\text{valor-p} < \alpha$, se rechaza H_0 .

Cuidado

El valor-p no es la probabilidad de que H_0 sea verdadera.




Valor-p: idea visual



Lectura

El valor-p corresponde al área de resultados tan extremos o más extremos que el observado, bajo el supuesto de que H_0 es verdadera.



Interpretaciones incorrectas del valor-p




El valor-p no es

- la probabilidad de que H_0 sea verdadera;
- la probabilidad de que el resultado sea producto del azar;
- el tamaño del efecto;
- una medida directa de importancia práctica.

Interpretación útil

Un valor-p pequeño indica que los datos observados serían poco habituales si H_0 fuera verdadera.






Ejercicio 4.

Una prueba entrega valor-p igual a 0.018. El nivel de significancia fijado fue $\alpha = 0.05$.

1. ¿Se rechaza H_0 ?
2. ¿Cómo interpretaría este resultado?
3. ¿Sería correcto decir que hay 1.8 % de probabilidad de que H_0 sea verdadera?



Conexión entre IC y prueba de hipótesis



Idea



Para pruebas bilaterales, un intervalo de confianza puede entregar una decisión equivalente.

Si el valor hipotético queda dentro

No hay evidencia suficiente para rechazar H_0 .

Si el valor hipotético queda fuera

Existe evidencia para rechazar H_0 .






Ejercicio 5.

Una empresa afirma que el tiempo promedio de atención es $\mu = 10$ minutos. Un estudio obtiene el intervalo de confianza 95 %:

$$(10.8, 13.4).$$

1. ¿El valor 10 queda dentro del intervalo?
2. ¿Qué decisión sugiere esto para una prueba bilateral al 5 %?
3. Interprete el resultado en contexto.






- Los intervalos de confianza comunican precisión de una estimación.
- El margen de error depende de variabilidad, tamaño muestral y nivel de confianza.
- Las pruebas de hipótesis comparan evidencia con una afirmación base.
- El nivel de significancia controla el riesgo de falso positivo.
- El valor-p mide compatibilidad de los datos con H_0 .

Conexión

La próxima clase desarrolla pruebas paramétricas para una y dos poblaciones.



Mapa del curso



INGENIERÍA
INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso
2. Conceptos básicos de probabilidad
3. Bayes, variables aleatorias y distribuciones
4. Esperanza, varianza y desviación estándar
5. Modelos probabilísticos discretos
6. Modelos probabilísticos continuos
7. Conceptos básicos de estadística
8. Propiedades de estimadores y Teorema Central del Límite
9. Intervalos de confianza e introducción a hipótesis
10. Pruebas de hipótesis paramétricas
 - 10.1 Fundamentos
 - 10.2 Estadístico de prueba, región crítica y valor-p
 - 10.3 Prueba Z para una media
 - 10.4 Prueba t para una media
 - 10.5 Prueba para una proporción
 - 10.6 Dos poblaciones independientes
 - 10.7 Dos proporciones
 - 10.8 Integración y cierre




Las empresas suelen operar con estándares:

- tiempo promedio máximo;
- proporción máxima de defectos;
- peso objetivo;
- duración mínima esperada;
- nivel de servicio comprometido.



Pregunta

¿La evidencia muestral indica que el proceso cumple el estándar o se desvió de él?




Objetivos



1. Formular pruebas para una media y una proporción.
2. Interpretar pruebas bilaterales y unilaterales.
3. Comprender el estadístico de prueba como evidencia estandarizada.
4. Introducir pruebas Z y t para una media.
5. Comparar dos poblaciones independientes.
6. Relacionar el resultado estadístico con una decisión industrial.

Enfoque

Esta sección conecta intervalos de confianza con pruebas paramétricas y prepara el tránsito hacia Inferencia Estadística.




Intervalo de confianza versus prueba de hipótesis



Intervalo de confianza

Pregunta:


¿Qué valores son plausibles?



Prueba de hipótesis

Pregunta:

¿Hay evidencia contra una afirmación?




Conexión

Ambos procedimientos usan la misma lógica: comparar evidencia muestral con incertidumbre.




Flujo completo de una prueba



Idea clave

La prueba no termina en “rechazar” o “no rechazar”. Debe traducirse a una decisión o diagnóstico industrial.



Hipótesis nula y alternativa



H_0 : hipótesis nula

Representa el estado base, estándar o afirmación inicial.

$$H_0 : \mu = \mu_0$$

Ejemplo

El tiempo promedio cumple el estándar:

$$H_0 : \mu = 30.$$

H_1 : hipótesis alternativa


Representa el cambio, diferencia o efecto de interés.

$$H_1 : \mu \neq \mu_0$$

Ejemplo

El tiempo promedio se desvió:

$$H_1 : \mu \neq 30.$$



Pruebas unilaterales y bilaterales



Derecha

$$H_1 : \mu > \mu_0$$


Detecta aumentos.



Izquierda

$$H_1 : \mu < \mu_0$$


Detecta reducciones.



Bilateral

$$H_1 : \mu \neq \mu_0$$

Detecta diferencias.






Ejercicio 1.

Una empresa tiene tres preguntas distintas:

1. Sospecha que el tiempo promedio de despacho aumentó respecto de 48 horas.
2. Quiere verificar si el peso promedio difiere de 500 gramos.
3. Desea comprobar si una mejora redujo el tiempo promedio de armado.

Para cada caso, formule H_0 y H_1 , e indique si la prueba es unilateral o bilateral.







Idea

Un estadístico de prueba transforma la evidencia observada en una escala común.



$$\text{estadístico} = \frac{\text{estimación observada} - \text{valor bajo } H_0}{\text{error estándar}}.$$






Idea

La región crítica contiene valores del estadístico que serían poco plausibles si H_0 fuera verdadera.



Definición intuitiva

El valor-p mide qué tan compatible es la evidencia observada con H_0 .



Regla

Si $\text{valor-p} < \alpha$, se rechaza H_0 .





Supuestos principales

- Observaciones independientes.
- Desviación estándar poblacional σ conocida o histórica.
- Población normal o tamaño muestral suficientemente grande.

$$Z = \frac{\bar{X} - \mu_0}{\sigma / \sqrt{n}}.$$

Distribución bajo H_0

Si H_0 es verdadera:

$$Z \sim N(0, 1).$$




¿Qué significa $Z = 2$?



Interpretación


$$Z = 2$$

significa que la media observada está a dos errores estándar del valor planteado por H_0 .



Lectura

Mientras más lejos esté el estadístico de 0, menos compatible es la evidencia con H_0 .



Ejemplo: tiempo promedio



Un estándar indica que el tiempo promedio debe ser 10 minutos. Se observa:


$$n = 64, \quad \bar{x} = 10.8, \quad \sigma = 3.2.$$

$$H_0 : \mu = 10, \quad H_1 : \mu > 10.$$

$$Z = \frac{10.8 - 10}{3.2/\sqrt{64}} = \frac{0.8}{0.4} = 2.0.$$

Valor-p unilateral:

$$\mathbb{P}(Z > 2) = 0.0228.$$



Interpretación del ejemplo



Con $\alpha = 0.05$:

$$0.0228 < 0.05.$$

Por lo tanto, se rechaza H_0 .

Conclusión estadística

Existe evidencia de que el tiempo promedio supera los 10 minutos.

Conclusión operacional

El proceso podría estar incumpliendo el estándar de atención y requiere revisión.

Cuidado

Rechazar H_0 no dice automáticamente que el efecto sea grande o económicamente relevante.






Suponga la misma diferencia observada:

$$\bar{x} - \mu_0 = 0.8, \quad \sigma = 3.2.$$

n	Error estándar	Z
16	$3.2/4 = 0.80$	1.00
64	$3.2/8 = 0.40$	2.00
256	$3.2/16 = 0.20$	4.00

Idea

Con más datos, una misma diferencia puede volverse más evidente estadísticamente.






Ejercicio 2.

Una planta afirma que el tiempo promedio de preparación es 30 minutos. En una muestra de $n = 36$ órdenes se obtiene $\bar{x} = 32$ y desviación estándar histórica $\sigma = 6$.

1. Formule H_0 y H_1 para detectar aumento.
2. Calcule el estadístico de prueba.
3. Decida con $\alpha = 0.05$ usando valor-p unilateral.
4. Interprete operacionalmente el resultado.



Cuando σ es desconocida



En la mayoría de los problemas reales, σ no se conoce.

Solución


Se reemplaza σ por la desviación estándar muestral s .

$$t = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}.$$

Distribución bajo H_0

Si los supuestos son adecuados:


$$t \sim t_{n-1}.$$






Idea

La distribución t tiene colas más pesadas porque incorpora la incertidumbre de estimar σ con s .



La diferencia disminuye cuando n crece.



Ejemplo: prueba t para una media



Una línea de ensamblaje tiene estándar:

$$\mu_0 = 25 \text{ minutos.}$$

Se toma una muestra de $n = 16$ órdenes:


$$\bar{x} = 27.1, \quad s = 4.2.$$

$$H_0 : \mu = 25, \quad H_1 : \mu > 25.$$

$$t = \frac{27.1 - 25}{4.2/\sqrt{16}} = \frac{2.1}{1.05} = 2.0.$$

Grados de libertad:

$$gl = n - 1 = 15.$$






Ejercicio 3.

Una empresa quiere verificar si el tiempo promedio de atención supera 20 minutos. En una muestra de $n = 25$ clientes se obtiene:

$$\bar{x} = 21.4, \quad s = 3.5.$$

1. Formule H_0 y H_1 .
2. Calcule el estadístico t .
3. Indique los grados de libertad.
4. Explique qué significaría un valor-p menor que 0.05.



Prueba para una proporción



Para contrastar:

$$H_0 : p = p_0,$$


se utiliza:

$$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)/n}}.$$

Condición de aproximación

Se requiere que los conteos esperados bajo H_0 sean suficientemente grandes:

$$np_0 \quad \text{y} \quad n(1 - p_0).$$



Ejemplo: proporción de defectos



El máximo aceptable es 5 % de defectos. En $n = 300$ piezas se observan 24 defectuosas.


$$\hat{p} = \frac{24}{300} = 0.08.$$

$$H_0 : p = 0.05, \quad H_1 : p > 0.05.$$

$$Z = \frac{0.08 - 0.05}{\sqrt{0.05(0.95)/300}} = 2.38.$$

Valor-p:

$$\mathbb{P}(Z > 2.38) \approx 0.0087.$$



Conclusión del ejemplo



Con $\alpha = 0.05$:

$$0.0087 < 0.05.$$


Se rechaza H_0 .

Conclusión estadística

Hay evidencia de que la proporción de defectos supera el 5 %.

Conclusión industrial

La situación puede activar revisión de proceso, análisis de causa raíz o aumento temporal de inspección.






Ejercicio 4.

Una empresa establece que la proporción máxima de entregas atrasadas es 4 %. En una muestra de $n = 500$ entregas se observan 31 atrasos.

1. Calcule $\hat{p}$.
2. Formule H_0 y H_1 para detectar incumplimiento.
3. Calcule el estadístico Z .
4. Interprete la decisión si el valor-p es menor que 0.05.



Comparación de dos medias independientes



Queremos comparar dos procesos, proveedores, plantas o métodos.

$$H_0 : \mu_1 - \mu_2 = \Delta_0.$$

Grupo 1

$$\bar{X}_1, \quad n_1, \quad s_1$$

Grupo 2

$$\bar{X}_2, \quad n_2, \quad s_2$$

Idea

La evidencia está en la diferencia observada:

$$\bar{X}_1 - \bar{X}_2.$$





Con muestras grandes o varianzas conocidas:

$$Z = \frac{(\bar{X}_1 - \bar{X}_2) - \Delta_0}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}.$$


Si las varianzas son desconocidas, se usa una versión basada en t .

Interpretación

Δ_0 es la diferencia postulada bajo H_0 , usualmente 0.

Supuesto clave

Las muestras deben ser independientes. Si las observaciones están emparejadas, se requiere otro procedimiento.



Ejemplo: proveedores



Proveedor A:

$$n_1 = 40, \quad \bar{x}_1 = 5.2, \quad s_1 = 1.1.$$


Proveedor B:

$$n_2 = 45, \quad \bar{x}_2 = 4.7, \quad s_2 = 1.0.$$

$$H_0 : \mu_A - \mu_B = 0, \quad H_1 : \mu_A - \mu_B > 0.$$

Aproximando con Z :

$$Z = \frac{0.5}{\sqrt{1.1^2/40 + 1.0^2/45}} = 2.19.$$





Valor-p unilateral aproximado:

$$0.014.$$

Con $\alpha = 0.05$:


$$0.014 < 0.05.$$

Conclusión estadística

Hay evidencia de que el proveedor A tarda más que el proveedor B en promedio.

Decisión industrial

La significancia estadística debe complementarse con costo, confiabilidad, calidad y capacidad contractual.






Ejercicio 5.

Una empresa compara dos centros de distribución.

$$n_1 = 50, \quad \bar{x}_1 = 18.4, \quad s_1 = 4.0.$$

$$n_2 = 60, \quad \bar{x}_2 = 16.9, \quad s_2 = 3.8.$$

1. Formule hipótesis para evaluar si el centro 1 tarda más que el centro 2.
2. Calcule la diferencia observada de medias.
3. Escriba el error estándar aproximado de la diferencia.
4. Explique cómo usaría el estadístico para tomar una decisión.



Comparación de dos proporciones



Queremos contrastar:

$$H_0 : p_1 - p_2 = 0.$$

Ejemplos

- Dos líneas de producción.
- Dos proveedores.
- Dos campañas de servicio.
- Dos centros logísticos.

Pregunta

¿La diferencia observada entre proporciones refleja una diferencia real o solo variación muestral?



Proporción combinada bajo H_0 

Si $H_0 : p_1 = p_2$ es verdadera, ambas muestras estiman una misma proporción común.

$$\hat{p}_c = \frac{x_1 + x_2}{n_1 + n_2}.$$

Interpretación

La proporción combinada estima la tasa común postulada bajo H_0 .

$$Z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}_c(1 - \hat{p}_c)(1/n_1 + 1/n_2)}}.$$



Ejemplo: dos líneas de producción



Línea A:


$$n_1 = 400, \quad x_1 = 32, \quad \hat{p}_1 = 0.08.$$

Línea B:

$$n_2 = 350, \quad x_2 = 14, \quad \hat{p}_2 = 0.04.$$

$$H_0 : p_A - p_B = 0, \quad H_1 : p_A - p_B > 0.$$

$$\hat{p}_c = \frac{32 + 14}{400 + 350} = \frac{46}{750} = 0.0613.$$





$$Z = \frac{0.08 - 0.04}{\sqrt{0.0613(1 - 0.0613)(1/400 + 1/350)}}.$$


$$Z \approx 2.27.$$

Valor-p unilateral aproximado:

$$0.0116.$$

Conclusión

A nivel 5 %, hay evidencia de que la línea A tiene mayor proporción de defectos que la línea B.






Ejercicio 6.

Una empresa compara dos proveedores.

$$n_1 = 300, \quad x_1 = 21$$

$$n_2 = 280, \quad x_2 = 11$$

1. Calcule $\hat{p}_1$ y $\hat{p}_2$.
2. Formule una prueba para evaluar si el proveedor 1 tiene mayor tasa de defectos.
3. Calcule la proporción combinada.
4. Escriba el estadístico Z correspondiente.



Significancia estadística versus relevancia práctica



Idea

Una diferencia puede ser estadísticamente significativa y, aun así, tener poca importancia operacional.

Ejemplo

Con una muestra muy grande, una reducción promedio de 0.05 segundos puede producir valor- p pequeño.

$$p < 0.001.$$

Pregunta industrial

¿El beneficio justifica el costo de cambiar el proceso?



Conexión entre IC y pruebas





Para pruebas bilaterales:

Valor hipotético dentro del IC

No hay evidencia suficiente para rechazar H_0 .

Valor hipotético fuera del IC

Existe evidencia para rechazar H_0 .






Ejercicio 7.

Una empresa afirma que el tiempo promedio de atención es 12 minutos. Un estudio obtiene:

$$IC_{95\%} = (12.8, 15.1).$$

1. ¿El valor 12 es plausible según el intervalo?
2. ¿Qué sugiere esto para una prueba bilateral al 5 %?
3. ¿Qué conclusión operacional comunicaría?






- Las pruebas paramétricas evalúan afirmaciones sobre medias y proporciones.
- Las pruebas unilaterales detectan una dirección específica; las bilaterales detectan diferencias.
- El estadístico de prueba mide distancia respecto de H_0 en errores estándar.
- La prueba Z se usa cuando σ es conocida o n es grande.
- La prueba t aparece cuando σ es desconocida.
- La conclusión estadística debe traducirse a una decisión operacional.

Conexión

La siguiente clase estudia muestras pareadas, donde las observaciones están naturalmente vinculadas.



Mapa del curso



INGENIERÍA
INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso
2. Conceptos básicos de probabilidad
3. Bayes, variables aleatorias y distribuciones
4. Esperanza, varianza y desviación estándar
5. Modelos probabilísticos discretos
6. Modelos probabilísticos continuos
7. Conceptos básicos de estadística
8. Propiedades de estimadores y Teorema Central del Límite
9. Intervalos de confianza e introducción a hipótesis
10. Pruebas de hipótesis paramétricas
- 11. Pruebas para muestras pareadas**
 - 11.1 Motivación
 - 11.2 Construcción de diferencias
 - 11.3 Prueba t pareada
 - 11.4 Ejemplo completo
 - 11.5 Intervalos de confianza
 - 11.6 Interpretación
 - 11.7 Ejercicios






A veces comparamos dos condiciones sobre la misma unidad:

- tiempo antes y después de una mejora;
- consumo energético antes y después de una intervención;
- productividad antes y después de capacitación;
- defectos antes y después de mantenimiento.

Pregunta

¿El cambio observado corresponde a una mejora real o puede explicarse por variabilidad muestral?




¿Por qué parear?




Problema

Las unidades suelen ser distintas entre sí.



Idea

Comparar cada unidad consigo misma elimina gran parte de la variabilidad entre individuos.




Independientes versus pareadas




Caso	Ejemplo	Método
Independiente	Planta A vs Planta B	Dos muestras
Pareado	Antes vs Después	Diferencias

Clave

Cada observación posee una pareja natural.



Visualización del pareamiento






Definimos:

$$D_i = X_{i,\text{después}} - X_{i,\text{antes}}.$$

Idea clave

Toda la inferencia estadística se realiza sobre las diferencias.



Importancia del signo



Si definimos:

$$D = \text{después} - \text{antes},$$


entonces:

$$D < 0 \Rightarrow \text{reducción}$$

$$D > 0 \Rightarrow \text{aumento}$$

Cuidado

Cambiar la definición cambia la interpretación de la hipótesis.



Hipótesis sobre la diferencia media



La prueba estudia:


$$H_0 : \mu_D = 0.$$

Alternativas habituales:

$$H_1 : \mu_D < 0$$

$$H_1 : \mu_D > 0$$

$$H_1 : \mu_D \neq 0$$






Una vez calculadas las diferencias:

$$D_1, D_2, \dots, D_n$$

el problema se transforma en una prueba t para una muestra.

Idea

La variable analizada es la diferencia.





Con:


$$\bar{d}, \quad s_D, \quad n$$

utilizamos:

$$t = \frac{\bar{d} - \mu_{D,0}}{s_D / \sqrt{n}}.$$


Normalmente:



$$\mu_{D,0} = 0.$$





1. Observaciones correctamente pareadas.
2. Diferencias independientes.
3. Distribución aproximadamente normal de las diferencias o muestra suficientemente grande.





Ejemplo: mejora de proceso




Diferencias observadas:

$-3, -2, -4, -1, -2, -5, -3, -2.$

Hipótesis:

$$H_0 : \mu_D = 0$$

$$H_1 : \mu_D < 0.$$






$$\bar{d} = -2.75$$

$$s_D \approx 1.28$$

$$n = 8.$$

Todos los cambios observados indican reducción.






$$t = \frac{-2.75}{1.28/\sqrt{8}} = -6.08.$$

Interpretación

La reducción promedio es grande respecto de la variabilidad observada.



Conclusión



Con:

$$gI = 7$$


el valor-p es extremadamente pequeño.

Conclusión

Existe evidencia de reducción del tiempo promedio.

Lectura industrial

Cuantificar ahorro económico asociado.




Intervalo para la diferencia media



$$\bar{d} \pm t_{\alpha/2, n-1} \frac{s_D}{\sqrt{n}}.$$

Interpretación

Cuantifica el tamaño plausible del cambio promedio.



Relación entre prueba e intervalo




Si:

0

queda fuera del intervalo, entonces:

- existe evidencia de cambio;
- una prueba bilateral rechazaría H_0 .



Significancia versus magnitud



Suponga:


$$\bar{d} = -0.2$$

minutos.

Con una muestra enorme podría resultar significativo.

Pregunta

¿Vale la pena cambiar todo el proceso por una mejora de 12 segundos?



La pregunta correcta




No basta preguntar:

¿Existe evidencia?

También debemos preguntar:

¿El cambio genera valor?






Ejercicio 1.

Una empresa registra consumo energético antes y después de instalar un sistema de control:

$-5, -3, -4, -2, -6, -3, -5.$

1. Formule hipótesis.
2. Interprete el signo.
3. ¿Qué indica una media negativa?






Ejercicio 2.

Una capacitación genera:

$$D = -1, -2, 0, -1, -3, -1.$$

1. Formule hipótesis.
2. Calcule $\bar{d}$.
3. Interprete el resultado.





Ejercicio 3.

Una prueba pareada entrega:

$$p = 0.003$$

y

$$\bar{d} = -0.4.$$

Discuta:


1. evidencia estadística;
2. relevancia operacional;
3. información adicional requerida.





Ejercicio 4.


Explique por qué analizar diferencias suele ser mejor que comparar directamente medias antes y después.



Errores frecuentes



- Tratar datos pareados como independientes.
- Definir diferencias con signo inconsistente.
- Concluir sólo usando valor-p.
- Ignorar factores externos.
- Analizar valores originales en lugar de diferencias.






- Las pruebas pareadas comparan mediciones vinculadas.
- El análisis se realiza sobre diferencias.
- La hipótesis se formula sobre μ_D .
- Son herramientas naturales para estudiar mejoras.

Conexión

La siguiente clase introduce pruebas chi-cuadrado para variables categóricas.




Mapa del curso



INGENIERÍA
INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso
2. Conceptos básicos de probabilidad
3. Bayes, variables aleatorias y distribuciones
4. Esperanza, varianza y desviación estándar
5. Modelos probabilísticos discretos
6. Modelos probabilísticos continuos
7. Conceptos básicos de estadística
8. Propiedades de estimadores y Teorema Central del Límite
9. Intervalos de confianza e introducción a hipótesis
10. Pruebas de hipótesis paramétricas
11. Pruebas para muestras pareadas





No todos los datos relevantes son numéricos continuos. Muchas decisiones industriales usan categorías:

- tipo de defecto;
- turno de producción;
- proveedor;
- nivel de satisfacción;
- zona de despacho;
- causa de reclamo.

Idea

Las pruebas chi-cuadrado permiten analizar conteos categóricos comparando lo observado con lo esperado.



¿Qué tipo de pregunta queremos responder?



Bondad de ajuste

¿Los conteos siguen una distribución propuesta?

$$O_i \approx E_i$$

Independencia

¿Dos variables categóricas están asociadas?

$$X \perp Y?$$


Homogeneidad

¿Varios grupos tienen la misma distribución?

$$p_1 = p_2 = \dots$$

Conexión

Las tres pruebas usan la misma lógica: comparar frecuencias observadas con frecuencias esperadas bajo H_0 .




Objetivos



1. Aplicar la prueba de bondad de ajuste.
2. Evaluar independencia en tablas de contingencia.
3. Comparar distribuciones categóricas mediante homogeneidad.
4. Interpretar frecuencias observadas y esperadas.
5. Comunicar conclusiones estadísticas en contexto industrial.

Meta

No solo calcular χ^2 , sino entender qué discrepancias explican el resultado.



Frecuencias observadas y esperadas



Frecuencia observada

$$O_i$$

Conteo real observado en la categoría i .

Frecuencia esperada

$$E_i$$

Conteo que se esperaría si H_0 fuera verdadera.

El estadístico general es:

$$\chi^2 = \sum_i \frac{(O_i - E_i)^2}{E_i}.$$

Interpretación

Mientras mayor sea la discrepancia entre observados y esperados, mayor será χ^2 .




Contribución de cada categoría



Idea

Cada categoría aporta una parte al estadístico:

$$\frac{(O_i - E_i)^2}{E_i}.$$




Forma de la distribución chi-cuadrado




Propiedades

- Toma valores no negativos.
- Es asimétrica a la derecha.
- Depende de los grados de libertad.



Regla

Valores grandes de χ^2 indican evidencia contra H_0 .




Condiciones de uso



- Los datos deben ser conteos, no porcentajes aislados.
- Las categorías deben ser mutuamente excluyentes.
- Las observaciones deben ser independientes.
- Las frecuencias esperadas no deben ser demasiado pequeñas.

Cuidado

Un resultado significativo indica discrepancia, asociación o diferencia de distribuciones, pero no prueba causalidad por sí solo.





Pregunta

¿Los datos observados siguen una distribución categórica propuesta?

Ejemplo industrial

Una empresa cree que los defectos se distribuyen:

50 % tipo A, 30 % tipo B, 20 % tipo C.

¿Los datos observados apoyan esa distribución?

Hipótesis

H_0 : la distribución observada coincide con la propuesta.

H_1 : la distribución observada difiere de la propuesta.

Cálculo de esperados en bondad de ajuste




Si el total observado es n y la probabilidad propuesta para la categoría i es p_i , entonces:

$$E_i = np_i.$$

Categoría	A	B	C
Proporción propuesta	0.50	0.30	0.20
Si $n = 100$	50	30	20

Idea

Los esperados son los conteos que deberíamos observar si H_0 fuera verdadera.



Ejemplo: bondad de ajuste




En 100 defectos observados:

Tipo	A	B	C
Observado	60	25	15
Esperado	50	30	20

$$\chi^2 = \frac{(60 - 50)^2}{50} + \frac{(25 - 30)^2}{30} + \frac{(15 - 20)^2}{20}.$$

$$\chi^2 = 2.00 + 0.83 + 1.25 = 4.08.$$



Conclusión: bondad de ajuste



Los grados de libertad son:

$$g/l = k - 1 = 3 - 1 = 2.$$

A nivel 5 %, el valor crítico es aproximadamente:

$$\chi^2_{0.95,2} = 5.99.$$

Como:

$$4.08 < 5.99,$$

Conclusión

No se rechaza H_0 . No hay evidencia suficiente para afirmar que la distribución de defectos difiere de la propuesta.





Ejercicio 1.


Una empresa espera que las quejas se distribuyan así:

40 % despacho, 35 % calidad, 25 % facturación.

En 200 quejas observa:

Categoría	Despacho	Calidad	Facturación
Observado	90	60	50

Realice una prueba de bondad de ajuste al 5 %.





Pregunta

¿Dos variables categóricas están asociadas?

Ejemplo


¿El tipo de defecto depende del turno de producción?

Hipótesis nula

H_0 : las variables son independientes.

Hipótesis alternativa

H_1 : existe asociación.



Frecuencia esperada en una tabla



Para una celda (i, j) :


$$E_{ij} = \frac{(\text{total fila } i)(\text{total columna } j)}{\text{total general}}.$$

Luego:

$$\chi^2 = \sum_i \sum_j \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

Grados de libertad:

$$gl = (\text{filas} - 1)(\text{columnas} - 1).$$



Ejemplo: independencia



Defectos por turno:

	Tipo A	Tipo B	Total
Día	30	20	50
Noche	10	40	50
Total	40	60	100

Bajo independencia:

$$E_{\text{Día,A}} = \frac{50 \times 40}{100} = 20.$$

Lectura

Si turno y tipo de defecto fueran independientes, esperaríamos 20 defectos tipo A en el turno día.



Frecuencias esperadas




	Tipo A	Tipo B
Día	20	30
Noche	20	30

$$\chi^2 = \frac{(30 - 20)^2}{20} + \frac{(20 - 30)^2}{30} + \frac{(10 - 20)^2}{20} + \frac{(40 - 30)^2}{30}.$$

$$\chi^2 = 5 + 3.33 + 5 + 3.33 = 16.67.$$

$$gI = (2 - 1)(2 - 1) = 1.$$



Conclusión: independencia



Con $g/l = 1$, el valor crítico al 5 % es:

3.84.

Como:


$16.67 > 3.84$,

Conclusión estadística

Se rechaza H_0 . Existe evidencia de asociación entre turno y tipo de defecto.

Interpretación industrial

La noche concentra relativamente más defectos tipo B; conviene investigar condiciones de operación, personal o mantenimiento.



Asociación significativa no implica asociación fuerte



Problema

La prueba chi-cuadrado responde:

¿Existe asociación?

pero no responde:

¿Qué tan fuerte es la asociación?

Ejemplo


Con muestras muy grandes es posible obtener:

$$p < 0.001$$

incluso cuando la asociación es débil desde el punto de vista práctico.

#SOMOSUSACH
Idea clave

Necesitamos una medida de tamaño de efecto



Coeficiente Phi (ϕ)

Para tablas:

$$2 \times 2$$

podemos utilizar:

$$\phi = \sqrt{\frac{\chi^2}{n}}.$$


Interpretación

$$\phi = 0$$

indica ausencia de asociación.

Valores más grandes indican asociaciones más fuertes.

ϕ	Intensidad
0.10	Débil





Para tablas generales:

$$r \times c$$

utilizamos:

$$V = \sqrt{\frac{\chi^2}{n(k-1)}}$$

donde:

$$k = \min(r, c).$$

Ventaja

Permite comparar intensidad de asociación entre tablas de distintos tamaños.




Interpretación de V de Cramér



V	Interpretación
0.00–0.10	Muy débil
0.10–0.30	Débil
0.30–0.50	Moderada
0.50–0.70	Fuerte
>0.70	Muy fuerte

Importante

Estos valores son referencias aproximadas y siempre deben interpretarse en contexto.



Ejemplo: intensidad de asociación



En la tabla anterior obtuvimos:

$$\chi^2 = 16.67$$

con

$$n = 100.$$

Como la tabla es:

$$2 \times 2$$

podemos calcular:

$$\phi = \sqrt{\frac{16.67}{100}} = 0.408.$$

Interpretación

Existe evidencia estadística de asociación y además la intensidad puede considerarse moderada.

Significancia versus tamaño de efecto



Resultado A

$$p < 0.001$$

$$V = 0.05$$

Asociación muy débil.

Resultado B

$$p < 0.001$$


$$V = 0.45$$

Asociación moderada-fuerte.

Idea clave

La significancia responde si existe evidencia.

El tamaño de efecto responde si la asociación es importante.



¿Dónde está la asociación?




Idea

Después de rechazar independencia, debemos identificar qué celdas explican la asociación.

	Tipo A	Tipo B
Día	$30 > 20$	$20 < 30$
Noche	$10 < 20$	$40 > 30$

Lectura

El turno día tiene más defectos A de lo esperado; el turno noche tiene más defectos B de lo esperado.





Problema

La prueba puede indicar asociación significativa:

$$\chi^2 \text{ grande}$$

pero no nos dice inmediatamente:


¿qué categorías explican el resultado?

Ejemplo

Sabemos que turno y tipo de defecto están asociados.

Pero:

¿Dónde aparece esa asociación?



Residuos observados versus esperados



Para cada celda calculamos:

$$O_{ij} - E_{ij}.$$

Interpretación

$$O > E$$


Más observaciones que las esperadas.

$$O < E$$

Menos observaciones que las esperadas.

Problema

Los residuos dependen de la escala de la tabla.





Una medida más útil es:

$$R_{ij} = \frac{O_{ij} - E_{ij}}{\sqrt{E_{ij}}}.$$


Interpretación

Valores cercanos a:

0

indican concordancia con independencia.

Valores grandes en magnitud indican discrepancias importantes.






Residuo	Interpretación
$ R < 2$	Normal
$2 \leq R < 3$	Atención
$ R \geq 3$	Discrepancia fuerte

Idea

Las celdas con residuos grandes suelen explicar la mayor parte del valor de χ^2 .



Ejemplo: turno y tipo de defecto



Recordemos:

$$O_{Da,A} = 30$$

$$E_{Da,A} = 20.$$

Entonces:

$$R = \frac{30 - 20}{\sqrt{20}} = 2.24.$$

Interpretación

Existen más defectos tipo A durante el día de los que esperaríamos bajo independencia.






	A	B
Día	+2.2	-1.8
Noche	-2.2	+1.8

Lectura

Rojo indica más observaciones de las esperadas.

Azul indica menos observaciones de las esperadas.



¿Por qué importan los residuos?




Resultado estadístico

Existe asociación entre turno y tipo de defecto.

Resultado operacional

Los residuos indican exactamente dónde concentrar los esfuerzos de mejora.

- capacitación;
- mantenimiento;
- control de calidad;
- supervisión.





Ejercicio 2.

Una empresa registra reclamos por canal de venta:

	Producto	Despacho	Total
Online	35	65	100
Presencial	55	45	100
Total	90	110	200

1. Formule H_0 y H_1 .
2. Calcule el esperado de la celda Online–Producto.
3. Explique qué pregunta responde la prueba.






Pregunta

¿Varias poblaciones o grupos tienen la misma distribución categórica?

Ejemplo

¿Tres proveedores presentan la misma distribución de tipos de defecto?

- La matemática es similar a independencia.
- Cambia la pregunta y el diseño de muestreo.




Independencia versus homogeneidad



Prueba	Pregunta	Diseño
Independencia	¿Variables asociadas?	Una muestra clasificada por dos variables
Homogeneidad	¿Distribuciones iguales?	Muestras de grupos distintos

Clave

El cálculo puede ser igual, pero la interpretación depende de cómo se obtuvieron los datos.



Ejemplo: homogeneidad



Tres proveedores reportan tipos de defecto:


Proveedor	Tipo A	Tipo B	Tipo C
P1	20	15	15
P2	10	25	15
P3	15	15	20

Pregunta

¿Los proveedores tienen la misma distribución de tipos de defecto?

H_0 : las distribuciones son homogéneas.

H_1 : al menos un proveedor difiere.



Interpretación de homogeneidad




Si se rechaza H_0 :

- no todos los grupos comparten la misma distribución;
- algún proveedor, planta o zona presenta un patrón distinto;
- se debe investigar qué categorías explican la diferencia.

Cuidado

La prueba no dice automáticamente cuál grupo causa la diferencia. Es necesario revisar las celdas observadas y esperadas.






Ejercicio 3.

Dos proveedores entregan defectos clasificados como leves o graves:

	Leve	Grave	Total
Proveedor A	40	10	50
Proveedor B	30	20	50


1. ¿La pregunta corresponde a independencia o a homogeneidad?
2. Formule H_0 y H_1 .
3. ¿Qué implicaría rechazar H_0 ?



Errores frecuentes



- Aplicar chi-cuadrado a promedios en lugar de conteos.
- Usar porcentajes sin conocer los totales.
- Confundir independencia con homogeneidad.
- Ignorar categorías con frecuencias esperadas bajas.
- Concluir causalidad solo a partir de asociación estadística.



Significancia versus interpretación




Resultado significativo

Indica que existe discrepancia, asociación o diferencia de distribuciones.

Pero no basta

Se debe interpretar:

- qué categorías explican el resultado;
- si la diferencia es relevante operacionalmente;
- si existen factores de confusión;
- qué acción industrial tiene sentido.






- Bondad de ajuste compara conteos observados con una distribución propuesta.
- Independencia evalúa asociación entre dos variables categóricas.
- Homogeneidad compara distribuciones categóricas entre grupos.
- Todas usan la lógica de discrepancia entre observados y esperados.

Conexión final

Estas pruebas completan una primera caja de herramientas para analizar datos e incertidumbre en Ingeniería Industrial.






Mensaje final

Probabilidad, estimación e inferencia son tres formas complementarias de razonar bajo incertidumbre.

- La probabilidad modela lo que podría ocurrir.
- La estadística descriptiva resume lo que observamos.
- La inferencia permite aprender sobre una población usando una muestra.
- Las pruebas de hipótesis permiten contrastar evidencia contra una afirmación operacional.



Competencias esperadas al finalizar



- Formular problemas aleatorios en lenguaje probabilístico.
- Identificar variables aleatorias y seleccionar modelos discretos o continuos simples.
- Interpretar esperanza, varianza y desviación estándar en problemas industriales.
- Diseñar estimaciones e intervalos de confianza básicos.
- Aplicar pruebas paramétricas y pruebas chi-cuadrado introductorias.
- Comunicar resultados estadísticos con interpretación práctica.

